BỘ GIÁO DỤC VÀ ĐÀO TẠO NGÂN HÀNG NHÀ NƯỚC VIỆT NAM

TRƯỜNG ĐẠI HỌC NGÂN HÀNG TP.HCM

KHOA HỆ THỐNG THÔNG TIN QUẢN LÝ

ĐỒ ÁN NHÓM

MÔN: HỌC MÁY

ĐỀ TÀI: DỰ ĐOÁN KHÁCH HÀNG RỜI BỎ (CUSTOMER CHURN PREDICTION)

Giảng viên hướng dẫn : Vương Trọng Nhân

Lớp học phần : DAT704_2511_1_D03

Nhóm : 8

Sinh viên thực hiện: Nguyễn Phan Thanh Lịch

Nguyễn Lê Yến Nhi

Vũ Thanh Phong

Võ Thị Thu Thảo

Trần Thị Ngọc Vy

Trần Thúy Vy

BỘ GIÁO DỤC VÀ ĐÀO TẠO NGÂN HÀNG NHÀ NƯỚC VIỆT NAM

TRƯỜNG ĐẠI HỌC NGÂN HÀNG TP.HCM

KHOA HỆ THỐNG THÔNG TIN QUẢN LÝ

ĐỒ ÁN NHÓM

MÔN: HỌC MÁY

ĐỀ TÀI: DỰ ĐOÁN KHÁCH HÀNG RỜI BỎ (CUSTOMER CHURN PREDICTION)

Giảng viên hướng dẫn : Vương Trọng Nhân

Lớp học phần : DAT704_2511_1_D03

Nhóm : 8

Sinh viên thực hiện: Nguyễn Phan Thanh Lịch

Nguyễn Lê Yến Nhi

Vũ Thanh Phong

Võ Thị Thu Thảo

Trần Thị Ngọc Vy

Trần Thúy Vy

BẢNG PHÂN CÔNG NHIỆM VỤ

Họ và tên	MSSV	Nhiệm vụ	Đánh giá
Nguyễn Phan Thanh Lịch	030239230103	- Báo cáo - Code - Bài tập Code	100%
Nguyễn Lê Yến Nhi	030239230161	- Báo cáo - Code - Bài tập Code	100%
Vũ Thanh Phong	030239230184	- Báo cáo - Code - Bài tập Code	100%
Võ Thị Thu Thảo	030239230223	- Báo cáo - Code - Bài tập Code	100%
Trần Thị Ngọc Vy	030239230296	- Báo cáo - Code - Bài tập Code	100%
Trần Thúy Vy (Nhóm trưởng)	030239230297	- Báo cáo + chỉnh word - Code - Bài tập Code	100%

MỤC LỤC

1. GIỚI THIỆU BÀI TOÁN 8

1.1. Đặt vấn đề 8

1.1.1. Sự chuyển dịch mô hình tăng trưởng trong ngành viễn thông hiện đại 8

1.1.2. Bài toán kinh tế 8

1.1.3. Khái niệm Customer Churn 9

1.1.4. Tại sao cần sử dụng Machine Learning để dự đoán Churn? 9

1.2. Mục tiêu đề tài 10

1.3. Phạm vi nghiên cứu 10

2. GIỚI THIỆU VỀ TẬP DỮ LIỆU 10

2.1. Nguồn dữ liệu 10

2.2. Mô tả dữ liệu 10

2.3. Phân tích khám phá dữ liệu (EDA) 14

2.3.1. Cơ bản về Exploratory Data Analysis (EDA) 14

2.3.2. Vai trò của EDA 14

2.3.3. Quy trình EDA với tập dữ liệu 14

2.3.4. Kiểm tra dữ liệu 17

2.3.5. Data Manipulation 18

2.3.6. Phân phối dữ liệu 19

2.3.7. Trực quan hóa dữ liệu 21

2.3.8. Ma trận tương quan 22

3. QUY TRÌNH XỬ LÝ 22

3.1. Tiền xử lý dữ liệu (Data Preprocessing) 22

3.2. Xử lý mất cân bằng dữ liệu 26

3.3. Chia tập dữ liệu 27

4. GIỚI THIỆU CÔNG CỤ, KỸ THUẬT VÀ THUẬT TOÁN 27

4.1. Công cụ và môi trường 27
4.2. Các thuật toán sử dụng 28
4.2.1. Rừng ngẫu nhiên (Random Forest) 28
4.2.2. XGBoost 28
4.2.3. Neural Networks 29
4.3. Các độ đo đánh giá (Evaluation Metrics) 29
4.4. Kỹ thuật giải thích mô hình (XAI) 30
4.4.1. SHAP (SHapley Additive exPlanations) 30
4.4.2. LIME (Local Interpretable Model-agnostic Explanations) 30
5. KẾT QUẢ THỰC NGHIỆM 30
5.1. Huấn luyện và đánh giá mô hình 30
5.2. Giải thích mô hình (XAI Results) 33
5.2.1. Tổng quan về tầm quan trọng của các đặc trưng (Feature Importance) 33
5.2.2. Phân tích chi tiết chiều hướng tác động (Summary Plot) 34
5.2.3. Phân tích chi tiết khách hàng cụ thể (Local Explanation) 37
6. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN 39
6.1. Kết luận 39
6.2. Hạn chế 39
TÀI LIỆU THAM KHẢO 40

DANH MỤC HÌNH ẢNH

Hình 1. Biểu đồ Histogram tenure *19*

Hình 2. Biểu đồ Histogram MonthlyCharges *20*

Hình 3. Biểu đồ Histogram TotalCharges *20*

Hình 4. Biểu đồ tròn by Gender *21*

Hình 5. Biểu đồ cột chồng by Contract Type *21*

Hình 6. Mô hình Random Forest *30*

Hình 7. Mô hình Logistic Regression *31*

Hình 8. Mô hình XGBoost *31*

Hình 9. Confusion Matrix-Random Forest *31*

Hình 10. Confusion Matrix-Logistic Regression *31*

Hình 11. Confusion Matrix-XGBoots *32*

Hình 12. Biểu đồ xếp hạng mức độ ảnh hưởng *33*

Hình 13. Biểu đồ chi tiết tác động của từng giá trị *35*

Hình 14. Khách hàng INDEX 156 ..... *37*

Hình 15. Biểu đồ SHAP Waterfall Plot *37*

DANH MỤC BẢNG BIỂU

Bảng 1. Dữ liệu chi tiết.....11

Bảng 2. Danh sách các biến phân loại và phương pháp mã hóa.....24

LỜI CẢM ƠN

Lời đầu tiên, chúng em xin bày tỏ lòng biết ơn sâu sắc đến thầy Vương Trọng Nhân, giảng viên môn Học máy, người đã tận tình giảng dạy, truyền đạt kiến thức chuyên môn và luôn đồng hành, định hướng cho chúng em trong suốt quá trình học tập cũng như thực hiện bài báo cáo này. Những kiến thức nền tảng về học máy, phương pháp xây dựng mô hình và cách tiếp cận bài toán dữ liệu mà thầy truyền đạt đã giúp chúng em hiểu rõ hơn bản chất của các thuật toán, đồng thời biết cách vận dụng chúng vào các bài toán thực tiễn.

Thông qua quá trình thực hiện đề tài, chúng em đã có cơ hội tiếp cận sâu hơn với quy trình phân tích dữ liệu và xây dựng mô hình dự đoán trong một bài toán thực tế - cụ thể là bài toán dự đoán khách hàng rời bỏ trong lĩnh vực viễn thông. Đây là trải nghiệm học tập ý nghĩa, giúp chúng em rèn luyện tư duy phân tích, kỹ năng xử lý dữ liệu và khả năng liên kết kiến thức học máy với các vấn đề trong kinh doanh và quản lý khách hàng.

Bên cạnh đó, quá trình làm việc nhóm đã giúp các thành viên nâng cao tinh thần trách nhiệm, kỹ năng phối hợp và trao đổi chuyên môn. Sự hỗ trợ, chia sẻ và đóng góp tích cực của từng thành viên là yếu tố quan trọng giúp bài báo cáo được hoàn thành đúng tiến độ và đạt được mục tiêu đề ra.

Mặc dù đã nỗ lực hoàn thành bài báo cáo với tinh thần nghiêm túc và cầu thị, do giới hạn về thời gian và kinh nghiệm thực tế, bài làm khó tránh khỏi những thiếu sót. Chúng em rất mong nhận được những ý kiến đóng góp và nhận xét từ thầy Vương Trọng Nhân để có thể hoàn thiện hơn kiến thức và kỹ năng trong quá trình học tập sau này. Cuối cùng, chúng em xin kính chúc thầy nhiều sức khỏe, hạnh phúc và tiếp tục gặt hái nhiều thành công trong sự nghiệp giảng dạy.

LỜI MỞ ĐẦU

Trong kỷ nguyên chuyển đổi số hiện nay, dữ liệu đã trở thành một nguồn tài nguyên quan trọng, đóng vai trò then chốt trong hoạt động quản trị và ra quyết định của doanh nghiệp. Việc thu thập, phân tích và khai thác dữ liệu một cách hiệu quả không chỉ giúp doanh nghiệp hiểu rõ hơn về khách hàng mà còn tạo ra lợi thế cạnh tranh bền vững trên thị trường. Đặc biệt, trong lĩnh vực viễn thông - một ngành có mức độ cạnh tranh cao và sự thay đổi nhanh chóng - việc tận dụng dữ liệu để phân tích hành vi khách hàng ngày càng trở nên cần thiết.

Một trong những thách thức lớn đối với các doanh nghiệp viễn thông hiện nay là tình trạng khách hàng rời bỏ dịch vụ. Việc mất đi khách hàng không chỉ làm suy giảm doanh thu mà còn ảnh hưởng đến hình ảnh thương hiệu và vị thế của doanh nghiệp trong dài hạn. Do đó, bài toán dự đoán khả năng rời bỏ của khách hàng (Customer Churn Prediction) đã và đang nhận được nhiều sự quan tâm trong nghiên cứu cũng như trong thực tiễn kinh doanh.

Xuất phát từ nhu cầu thực tiễn đó, nhóm tập trung nghiên cứu và khai thác bộ dữ liệu Telco Customer Churn, một tập dữ liệu phổ biến và có độ tin cậy cao trong lĩnh vực viễn thông. Thông qua việc áp dụng các phương pháp phân tích dữ liệu và kỹ thuật học máy, nhóm hướng đến việc xác định những yếu tố ảnh hưởng đến quyết định rời bỏ dịch vụ của khách hàng, từ đó xây dựng mô hình dự đoán nhằm hỗ trợ doanh nghiệp trong việc chủ động giữ chân khách hàng.

Thông qua đồ án này, nhóm mong muốn làm rõ vai trò của học máy và khoa học dữ liệu trong việc giải quyết các bài toán kinh doanh thực tiễn, đặc biệt là trong việc nâng cao hiệu quả quản lý khách hàng và phát triển bền vững cho doanh nghiệp viễn thông.

1. GIỚI THIỆU BÀI TOÁN

1.1. Đặt vấn đề

1.1.1. Sự chuyển dịch mô hình tăng trưởng trong ngành viễn thông hiện đại

Trong kỷ nguyên số hóa toàn cầu, ngành công nghiệp viễn thông đang trải qua một giai đoạn chuyển mình mang tính bước ngoặt. Từ chỗ tập trung mở rộng hạ tầng và thu hút thuê bao mới trong những thập kỷ trước, thị trường hiện nay tại các quốc gia phát triển và đang phát triển đã bước vào giai đoạn bão hòa. Sự phổ biến của các thiết bị di động thông minh và internet đã biến các dịch vụ viễn thông từ một tiện ích xa xỉ thành một nhu cầu thiết yếu hàng ngày, tương tự như điện và nước. Tuy nhiên, sự bão hòa này đồng nghĩa với việc "miếng bánh" thị phần không còn mở rộng nhanh chóng, dẫn đến sự cạnh tranh khốc liệt giữa các nhà cung cấp dịch vụ để giành giật thị phần từ tay đối thủ.

Trong bối cảnh cạnh tranh gay gắt, rào cản chuyển đổi đối với người tiêu dùng ngày càng giảm. Các chính sách như giữ số chuyển mạng, sự đa dạng của các gói cước giá rẻ và sự tương đồng về chất lượng dịch vụ giữa các nhà mạng khiến lòng trung thành của khách hàng trở nên mong manh hơn bao giờ hết. Điều này dẫn đến sự gia tăng của một chỉ số kinh doanh quan trọng và đáng báo động đó là tỷ lệ khách hàng rời bỏ.

Theo các báo cáo phân tích thị trường năm 2024 và dự báo cho năm 2025, ngành viễn thông đang phải đối mặt với tỷ lệ rời bỏ trung bình hàng năm ở mức cao. Cụ thể, số liệu thống kê cho thấy tỷ lệ rời bỏ trung bình của ngành viễn thông vào khoảng 21,5%, cao hơn nhiều so với ngành ngân hàng (15,3%) và y tế (8,7%). Đối với một nhà mạng viễn thông sở hữu 1 triệu thuê bao với doanh thu trung bình trên mỗi người dùng là 50 USD/tháng, việc chịu tỷ lệ churn 20% đồng nghĩa với việc doanh nghiệp đang để mất khoảng 120 triệu USD doanh thu mỗi năm. Con số khổng lồ này không chỉ là sự suy giảm doanh thu trực tiếp mà còn kéo theo sự lãng phí nguồn lực marketing, giảm giá trị thương hiệu và làm suy yếu vị thế cạnh tranh dài hạn của doanh nghiệp.

1.1.2. Bài toán kinh tế

Một trong những nguyên lý nền tảng thúc đẩy sự chuyển dịch trọng tâm từ "thu hút" sang "giữ chân" là sự chênh lệch to lớn giữa chi phí thu hút khách hàng mới (Customer Acquisition Cost - CAC) và chi phí giữ chân khách hàng hiện hữu (Customer Retention Cost - CRC). CAC bao gồm các khoản chi khổng lồ cho quảng cáo đại chúng, hoa hồng cho đại lý, chi phí thiết bị đầu cuối trợ giá, và các chi phí thiết lập dịch vụ ban đầu. Ngược lại, CRC thường chỉ bao gồm các chi phí chăm sóc khách hàng, các chương trình khách hàng thân thiết và các ưu đãi duy trì nhỏ. Do đó, bài toán đặt ra cho các doanh nghiệp viễn thông không còn đơn thuần là "Làm sao để có nhiều khách hàng nhất?" mà là "Làm sao để giữ chân những khách hàng giá trị nhất và ngăn chặn

họ rời bỏ?”. Đây chính là tiền đề cho sự ra đời và phát triển mạnh mẽ của các hệ thống dự báo churn (Churn Prediction Systems).

1.1.3. Khái niệm Customer Churn

Để giải quyết bài toán, trước hết Customer Churn là hiện tượng chấm dứt mối quan hệ thương mại giữa khách hàng và doanh nghiệp. Trong ngành viễn thông, điều này được định lượng bằng tỷ lệ phần trăm thuê bao ngừng sử dụng dịch vụ trong một khoảng thời gian nhất định. Khi nhắc đến “Churn Prediction”, tập trung chủ yếu vào rời bỏ tự nguyện (Voluntary Churn) là khi khách hàng chủ động đưa ra quyết định chấm dứt hợp đồng hoặc không gia hạn dịch vụ để chuyển sang nhà mạng đối thủ vì giá rẻ hơn, do tốc độ internet chậm, không hài lòng với thái độ phục vụ; bởi đây là nhóm đối tượng mà các chiến lược can thiệp của doanh nghiệp như giảm giá, chăm sóc khách hàng có thể mang lại hiệu quả thay đổi quyết định.

1.1.4. Tại sao cần sử dụng Machine Learning để dự đoán Churn?

Các phương pháp truyền thống trong việc quản lý churn thường mang tính chất phản ứng. Doanh nghiệp thường chỉ nhận biết khách hàng đã rời bỏ khi sự việc đã hoàn tất. Các nỗ lực giữ chân lúc này thường kém hiệu quả và tốn kém hơn nhiều so với việc giữ chân khách hàng khi họ mới chỉ có “ý định” rời bỏ.

Machine Learning giải quyết triệt để các vấn đề này bằng cách chuyển đổi phương thức tiếp cận từ “phản ứng” sang “chủ động”. Các thuật toán học máy có khả năng:

(1) Học từ lịch sử: Phân tích hành vi của những khách hàng đã rời bỏ trong quá khứ để tìm ra các “tín hiệu cảnh báo sớm”.

(2) Dự báo xác suất: Tính toán điểm số rủi ro cho từng khách hàng hiện hữu trong tương lai gần.

(3) Xử lý dữ liệu lớn: Tận dụng tối đa nguồn dữ liệu khổng lồ mà các nhà mạng sở hữu.

(4) Cải thiện độ chính xác: Các thuật toán hiện đại như Random Forest hay XGBoost đã được chứng minh là vượt trội so với các phương pháp thống kê truyền thống trong việc phân loại churn.

Tuy nhiên, doanh nghiệp không chỉ cần biết ai sẽ rời bỏ, mà quan trọng hơn là tại sao. Đây là lúc Explainable AI (XAI) trở thành mảnh ghép không thể thiếu, giúp minh bạch hóa các quyết định của mô hình để bộ phận kinh doanh có thể tin tưởng và hành động.

1.2. Mục tiêu đề tài

Xây dựng một quy trình khép kín từ tiền xử lý dữ liệu, xây dựng mô hình học máy để dự báo khách hàng có nguy cơ rời bỏ, đến việc giải thích kết quả mô hình nhằm hỗ trợ ra quyết định kinh doanh chiến lược cho doanh nghiệp viễn thông. Các mục tiêu cụ thể bao gồm:

(1) Phân tích đặc điểm và cấu trúc của bộ dữ liệu Telco Customer Churn.

(2) Xác định các yếu tố ảnh hưởng đến quyết định rời bỏ dịch vụ của khách hàng.

(3) Xây dựng mô hình học máy để dự đoán khách hàng rời bỏ.

(4) Từ các kết quả phân tích định lượng và định tính của mô hình, đề xuất các nhóm giải pháp kinh doanh cụ thể nhằm giảm thiểu tỷ lệ churn.

1.3. Phạm vi nghiên cứu

Để đảm bảo tính khả thi và tập trung, phạm vi nghiên cứu được giới hạn trên một số khía cạnh nhất định. Đề tài sử dụng bộ dữ liệu Telco Customer Churn do IBM cung cấp, bao gồm thông tin của 7.043 khách hàng cá nhân sử dụng các dịch vụ viễn thông tại bang California, Hoa Kỳ. Bộ dữ liệu gồm 21 thuộc tính, phản ánh thông tin nhân khẩu học, dịch vụ sử dụng và thông tin tài khoản của khách hàng. Dữ liệu có tính chất "snapshot", phản ánh trạng thái khách hàng tại một thời điểm và không bao gồm dữ liệu chuỗi thời gian.

Kết quả hướng tới việc hỗ trợ các doanh nghiệp viễn thông trong việc nhận diện và phân khúc nhóm khách hàng có nguy cơ rời bỏ, từ đó phục vụ cho các hoạt động chăm sóc khách hàng và xây dựng chiến lược giữ chân phù hợp.

2. GIỚI THIỆU VỀ TẬP DỮ LIỆU

2.1. Nguồn dữ liệu

Bộ dữ liệu được dùng trong nghiên cứu này là IBM Telco Customer Churn Dataset. Đây là một bộ dữ liệu mẫu được công bố bởi bộ phận IBM Cognos Analytics nhằm mục đích minh họa cho các khả năng phân tích dự báo trong lĩnh vực viễn thông. Bộ dữ liệu này hiện được lưu trữ và chia sẻ trên các nền tảng dữ liệu mở uy tín như Kaggle, đóng vai trò là một "bài toán mẫu" kinh điển cho phép sử dụng tự do khi nghiên cứu về bài toán churn.

2.2. Mô tả dữ liệu

Dữ liệu bao gồm 7.043 bản ghi với 21 thuộc tính, trong đó biến mục tiêu là Churn, thể hiện việc khách hàng có rời bỏ dịch vụ hay không. Các thuộc tính trong dữ liệu có thể được chia thành các nhóm chính như sau:

Bảng 1. Dữ liệu chi tiết

Nhóm	Tên biến	Kiểu dữ liệu	Mô tả chi tiết	Ý nghĩa kinh doanh
Định danh	customerID	String (Object)	Mã định danh duy nhất cho mỗi khách hàng (Ví dụ: 7590-VHVEG).	Dùng để truy vết, không có giá trị dự báo, cần loại bỏ khi huấn luyện mô hình.
Mục tiêu	Churn	String (Object)	Trạng thái rời bỏ của khách hàng trong tháng trước. Giá trị: "Yes" (Rời bỏ), "No" (Ở lại).	Biến phụ thuộc (Label) cần dự đoán.
Nhân khẩu học	gender	Categorical	Giới tính khách hàng (Female, Male).	Phân tích xem giới tính có ảnh hưởng đến độ trung thành không.
	SeniorCitizen	Integer (0/1)	Chỉ báo khách hàng là người cao tuổi (1) hay không (0).	Người cao tuổi thường ít thay đổi nhà mạng hơn do ngại công nghệ mới, hoặc ngược lại có thể nhạy cảm về giá.
	Partner	Categorical	Khách hàng có bạn đời hay không (Yes, No).	Người có gia đình thường ổn định hơn và ít rời bỏ dịch vụ hơn.
	Dependents	Categorical	Khách hàng có người phụ thuộc (con cái, cha mẹ già) hay không (Yes, No).	Tương tự Partner, hộ gia đình đông người thường gắn bó lâu dài.

Thông tin tài khoản	tenure	Integer	Số tháng khách hàng đã sử dụng dịch vụ của công ty.	Biến cực kỳ quan trọng. Khách hàng mới thường có nguy cơ rời bỏ cao nhất. Tenure càng cao, độ trung thành càng lớn.
	Contract	Categorical	Loại hợp đồng: Month-to-month (Tháng), One year (1 năm), Two year (2 năm).	Hợp đồng tháng tạo điều kiện dễ dàng để rời bỏ. Hợp đồng năm tạo rào cản pháp lý và cam kết.
	PaperlessBilling	Categorical	Hình thức nhận hóa đơn: Yes (Điện tử), No (Giấy).	Phản ánh mức độ am hiểu công nghệ và hành vi thanh toán.
	PaymentMethod	Categorical	Phương thức thanh toán: Electronic check, Mailed check, Bank transfer (auto), Credit card (auto).	Các phương thức tự động (Auto) thường giảm thiểu rủi ro quên thanh toán (Involuntary Churn).
	MonthlyCharges	Float	Số tiền cước phí hàng tháng khách hàng phải trả (USD).	Giá cao có thể là nguyên nhân chính gây rời bỏ nếu chất lượng không tương xứng.
	TotalCharges	Object/Float	Tổng số tiền khách hàng đã thanh toán từ khi bắt đầu sử dụng dịch vụ.	Phản ánh giá trị trọn đời (Customer Lifetime Value) tích lũy.
Dịch vụ đăng ký	PhoneService	Categorical	Có sử dụng dịch vụ điện thoại không (Yes, No).	Xác định loại hình dịch vụ chính.

	MultipleLines	Categorical	Có sử dụng nhiều đường dây không (Yes, No, No phone service).	Khách hàng dùng nhiều dịch vụ thường khó rời bỏ hơn.
	InternetService	Categorical	Nhà cung cấp dịch vụ Internet: DSL, Fiber optic (Cáp quang), No.	Công nghệ mạng ảnh hưởng trực tiếp đến trải nghiệm (tốc độ, độ ổn định).
	OnlineSecurity	Categorical	Dịch vụ bảo mật trực tuyến (Yes, No, No internet service).	Các dịch vụ giá trị gia tăng (VAS) giúp tăng độ gắn kết (Sticky services).
	OnlineBackup	Categorical	Dịch vụ sao lưu dữ liệu trực tuyến.	Tương tự OnlineSecurity.
	DeviceProtection	Categorical	Bảo hiểm thiết bị.	Tương tự OnlineSecurity.
	TechSupport	Categorical	Dịch vụ hỗ trợ kỹ thuật chuyên sâu.	Hỗ trợ tốt giúp giải quyết khiếu nại, giảm nguy cơ rời bỏ.
	StreamingTV	Categorical	Dịch vụ truyền hình trực tuyến.	Dịch vụ giải trí.
	StreamingMovies	Categorical	Dịch vụ xem phim trực tuyến.	Dịch vụ giải trí.

2.3. Phân tích khám phá dữ liệu (EDA)

2.3.1. Cơ bản về Exploratory Data Analysis (EDA)

Phân tích khám phá dữ liệu là một bước trong quy trình phân tích dữ liệu, bao gồm nhiều công việc, từ lúc nắm rõ dữ liệu mô tả tập dữ liệu (kích thước, dạng dữ liệu), đến thống kê mô tả các biến, xác định mối quan hệ giữa các biến, tìm ra những bất thường và ngoại lai trong dữ liệu,... Các câu hỏi sẽ được đặt ra nhằm tìm ra nhiều hướng khai thác và nhiều góc nhìn dữ liệu khác nhau. Từ các câu hỏi đó, cần tập trung vào trong tập dữ liệu và biết rằng sử dụng mô hình nào là phù hợp, và nên sử dụng kỹ thuật biến đổi, phân tích và trực quan hóa dữ liệu nào. Sẽ rất khó để có thể đặt ra câu hỏi chính xác ngay từ đầu tiên. Lý giải cho vấn đề này là bạn chưa nắm rõ các thông tin chi tiết của dữ liệu. Mặt khác, mỗi một câu hỏi sẽ giúp nhìn ra một khía cạnh mới trong dữ liệu và tăng khả năng nhìn nhận ra vấn đề tồn đọng trong dữ liệu. Mặc dù EDA được thực hiện ở nhiều giai đoạn khác nhau, nhưng thường được tiến hành trước khi phát triển một giả thuyết hoặc sau khi mục tiêu phân tích đã được xác định rõ.

2.3.2. Vai trò của EDA

(1) Hỗ trợ làm sạch dữ liệu với các kỹ thuật xác định các giá trị thiếu, sai sót hoặc các điểm dữ liệu bất thường: phân tích và khám phá dữ liệu ban đầu sẽ giúp phát hiện các vấn đề trong dữ liệu.

(2) Nắm rõ đặc điểm, cấu trúc và mô hình của tập dữ liệu: Mapping dữ liệu chính xác đảm bảo dữ liệu sử dụng ở chất lượng tốt khi chuyển đổi dữ liệu từ nguồn tới cơ sở dữ liệu, trang tính hoặc kho dữ liệu,... Hiểu rõ cấu trúc và mô hình của dữ liệu sẽ giúp hạn chế các lỗi sai có thể xảy ra.

(3) Xác định các biến quan trọng và mối quan hệ giữa các biến, hiểu cách các biến tương tác với nhau và ảnh hưởng của mỗi biến đối với kết quả phân tích.

(4) Xác định phạm vi sai lệch của dữ liệu: EDA giúp xác định những dữ liệu có thể dẫn đến các lỗi không thể tránh khỏi trong quá trình phân tích sau này. Việc biết dữ liệu nào sẽ ảnh hưởng đến kết quả phân tích giúp tránh được việc chấp nhận các kết luận sai hoặc gắn cho những kết quả phân tích sai lệch một ý nghĩa thống kê.

(5) Hiểu rõ hơn về đặc điểm mô tả của các biến và tập dữ liệu.

2.3.3. Quy trình EDA với tập dữ liệu

2.3.3.1. Đọc và khám phá dữ liệu

"Bước đầu tiên trong quá trình khám phá là xác định kích thước vật lý của bộ dữ liệu thông qua câu lệnh df.shape. Kết quả trả về (7043, 21) cung cấp một cái nhìn tổng thể về quy mô của bài toán: chúng ta đang sở hữu thông tin chi tiết của 7.043 khách hàng (tương ứng với số dòng), mỗi

khách hàng được định nghĩa bởi 21 đặc trưng (features) khác nhau (tương ứng với số cột). Với hơn 7.000 bản ghi, đây là một bộ dữ liệu có quy mô đủ lớn và đáng tin cậy để triển khai các thuật toán Machine Learning, cho phép mô hình học hỏi từ nhiều kịch bản hành vi khách hàng khác nhau. Đồng thời, sự hiện diện của 21 thuộc tính cho thấy tính đa chiều của dữ liệu, đòi hỏi nhóm phải thực hiện các bước phân tích sâu hơn để xác định xem trong số 21 biến này, đâu là những yếu tố then chốt thực sự tác động đến quyết định rời bỏ dịch vụ của khách hàng."

"Sau khi xác định được khung dữ liệu tổng thể, lệnh df.info() đã được thực hiện để cung cấp một cái nhìn chi tiết về 'sức khỏe' và bản chất kỹ thuật của từng biến số. Kết quả cho thấy một cấu trúc dữ liệu khá đa dạng với sự pha trộn giữa các biến định tính (object) và biến định lượng (int64, float64). Đáng chú ý, thông tin từ non-null count xác nhận rằng hầu hết các cột đều đầy đủ dữ liệu, tạo điều kiện thuận lợi cho việc phân tích mà không lo ngại về sự sai lệch do dữ liệu trống gây ra. Tuy nhiên, việc quan sát kỹ df.info() cũng giúp nhóm phát hiện ra những điểm cần xử lý kỹ thuật quan trọng: ví dụ như cột TotalCharges đang bị nhận diện nhầm là kiểu object thay vì kiểu số. Phát hiện này từ bước info() là tiền đề cực kỳ quan trọng để nhóm tiến hành ép kiểu dữ liệu và xử lý các ký tự trắng ẩn tiềm ẩn, đảm bảo tính chính xác tuyệt đối cho các phép toán thống kê và ma trận tương quan ở các bước sau."

2.3.3.2. Phân tích thống kê mô tả của các cột có kiểu dữ liệu object

(1) Tính độc nhất của khách hàng (customerID): Với chỉ số unique bằng đúng số lượng dòng (7.043), chúng ta xác nhận được mỗi bản ghi tương ứng với một khách hàng duy nhất. Đây là cột định danh và sẽ được loại bỏ trước khi huấn luyện mô hình để tránh gây nhiễu.

(2) Đặc điểm và dịch vụ phổ biến:

- InternetService: Loại hình dịch vụ chiếm ưu thế là Fiber optic (Cáp quang) với 3.096 khách hàng sử dụng. Trong thực tế, cáp quang thường đi kèm chi phí cao hơn nhưng tốc độ tốt hơn, đây là một biến số quan trọng cần theo dõi sát sao với tỷ lệ Churn.

- PhoneService: Đa số khách hàng (6.361/7.043) đều sử dụng dịch vụ điện thoại, cho thấy đây là sản phẩm cốt lõi của doanh nghiệp.

(3) Hành vi thanh toán và cam kết:

- Contract (Hợp đồng): Giá trị phổ biến nhất là Month-to-month (Theo tháng) với 3.875 khách hàng. Việc chiếm hơn 50% tổng số khách hàng ở loại hợp đồng ngắn hạn này là một dấu hiệu rủi ro cao, vì nhóm khách hàng này không có sự ràng buộc lâu dài và dễ dàng chuyển đổi sang nhà mạng khác.

- PaymentMethod: Hình thức thanh toán Electronic check (Séc điện tử) là phổ biến nhất (2.365).

(4) Phát hiện bất thường ở cột TotalCharges: Mặc dù mang ý nghĩa là số tiền, nhưng cột này xuất hiện trong bảng thống kê 'object' với 6.531 giá trị duy nhất. Điều đáng chú ý nhất là giá trị xuất hiện nhiều nhất (top) lại là các khoảng trắng trống (tần suất 11 lần). Đây là một phát hiện cực kỳ quan trọng của quá trình EDA, xác nhận rằng cột này cần được làm sạch, chuyển đổi kiểu dữ liệu và xử lý giá trị rỗng trước khi có thể đưa vào tính toán.

Bảng thống kê mô tả các biến định tính đã chỉ ra rằng khách hàng của doanh nghiệp chủ yếu là những người sử dụng cáp quang, thanh toán theo tháng và sử dụng séc điện tử. Đây chính là "phác họa chân dung" của nhóm khách hàng có biến động cao nhất, giúp định hướng cho các kỹ thuật lựa chọn đặc trưng (Feature Selection) trong giai đoạn tiếp theo.

2.3.3.3. Phân tích thống kê mô tả cho cột có dữ liệu số

Việc thực hiện phân tích thống kê mô tả tập trung vào ba cột số là SeniorCitizen, tenure và MonthlyCharges. Các con số thu được từ bộ dữ liệu 7.043 dòng đã cung cấp cái nhìn định lượng sơ khởi nhưng rất quan trọng. Trước hết, cột SeniorCitizen (Người cao tuổi) đóng vai trò là một biến phân loại số hóa với giá trị trung bình là 0,16. Con số này minh chứng rằng khoảng 16,2% khách hàng trong hệ thống là người cao tuổi. Đây là một tỉ trọng nhỏ nhưng có ý nghĩa chiến lược, bởi hành vi tiêu dùng và khả năng duy trì dịch vụ của nhóm này thường khác biệt hoàn toàn so với nhóm khách hàng trẻ. Tiếp theo, cột tenure (Số tháng gắn bó) bộc lộ sự phân hóa cực kỳ mạnh mẽ về lòng trung thành của khách hàng. Với giá trị trung bình là 32,37 tháng nhưng độ lệch chuẩn lên tới 24,56, dữ liệu cho thấy một khoảng cách lớn giữa các nhóm người dùng. Khoảng bách phân vị 25% đầu tiên chỉ đạt 9 tháng, trong khi bách phân vị 75% lên tới 55 tháng. Sự chênh lệch này, kết hợp với giá trị tối đa là 72 tháng, cho thấy doanh nghiệp đang phải đối mặt với một lượng lớn khách hàng mới gia nhập (nhóm có rủi ro rời bỏ cao nhất) bên cạnh một nhóm khách hàng kỳ cựu đã gắn bó tới 6 năm. Cuối cùng là MonthlyCharges (Phí hàng tháng), cột dữ liệu phản ánh trực tiếp doanh thu định kỳ. Mức phí trung bình là 64,76 USD, nhưng dải dao động lại cực rộng từ 18,25 USD đến 118,75 USD. Việc mức trung vị (50%) đạt 70,35 USD - cao hơn mức trung bình - cho thấy dữ liệu đang lệch nhẹ về phía các gói dịch vụ đắt tiền. Điều này đặt ra giả thuyết rằng những khách hàng đang trả phí cao (trên mức 70 USD) có thể là nhóm mục tiêu chính của các đối thủ cạnh tranh, dẫn đến nguy cơ Churn cao hơn nếu chất lượng dịch vụ không tương xứng với số tiền họ bỏ ra.

2.3.3.4. Phân tích biến mục tiêu: Churn

Biến mục tiêu Churn đóng vai trò quyết định trong việc định hình mô hình dự đoán. Qua quan sát biểu đồ phân phối, chúng ta nhận thấy một sự chênh lệch đáng kể giữa hai nhóm khách hàng, phản ánh một bài toán mất cân bằng dữ liệu (Class Imbalance) rõ rệt. Cụ thể, trong tổng số 7.043 quan sát, số lượng khách hàng lựa chọn ở lại (Churn = No) chiếm ưu thế tuyệt đối với 5.174

bản ghi, tương đương khoảng 73,4%. Trong khi đó, nhóm khách hàng thực sự rời bỏ dịch vụ (Churn = Yes) chỉ có 1.869 bản ghi, chiếm tỷ lệ khiêm tốn khoảng 26,6%. Tỷ lệ này xấp xỉ 3:1, cho thấy mặc dù lớp thiểu số (Yes) không quá thấp đến mức cực đoan, nhưng nó đủ để gây ra những sai lệch (bias) nhất định trong quá trình huấn luyện. Sự phân phối này mang lại hai nhận định quan trọng:

- Về mặt kinh doanh: Tỷ lệ rời bỏ hơn 26% là một con số báo động, cho thấy cứ khoảng 4 khách hàng thì có 1 người rời đi. Điều này minh chứng cho sự cần thiết của việc xây dựng mô hình dự báo để có các chiến dịch giữ chân khách hàng kịp thời.

- Về mặt kỹ thuật: Nếu sử dụng độ chính xác (Accuracy) làm thang đo duy nhất, mô hình chỉ cần dự đoán tất cả là "No" cũng có thể đạt được mức 73,4%, nhưng sẽ hoàn toàn thất bại trong việc tìm ra những người thực sự rời đi. Do đó, nhóm cần chuyển trọng tâm đánh giá sang các chỉ số như Recall (để không bỏ sót khách hàng rời đi) và F1-Score, đồng thời xem xét các kỹ thuật như SMOTE hoặc điều chỉnh Class Weight để cân bằng lại sức ảnh hưởng của hai lớp này trong quá trình tối ưu hóa thuật toán.

2.3.4. Kiểm tra dữ liệu

2.3.4.1. Kiểm tra giá trị thiếu

Việc kiểm tra dữ liệu thiếu là một bước "khám sức khỏe" bắt buộc để đảm bảo tính toàn vẹn cho mô hình Machine Learning. Qua thực thi câu lệnh df.isna().sum(), kết quả ghi nhận một tín hiệu rất tích cực khi hầu hết các trường thông tin trong tổng số 7.043 dòng đều đầy đủ, không xuất hiện giá trị NaN ở các cột quan trọng như gender, tenure hay MonthlyCharges.

Tuy nhiên, kết quả này cần được xem xét một cách thận trọng. Dù hệ thống báo cáo số lượng giá trị thiếu bằng 0, nhưng qua phân tích sâu, nhóm đã phát hiện ra các giá trị thiếu "ẩn" dưới dạng khoảng trắng trong cột TotalCharges (do kiểu dữ liệu đang là object). Đây là một bài học quan trọng trong EDA: dữ liệu không có giá trị Null về mặt kỹ thuật chưa chắc đã là dữ liệu sạch hoàn toàn. Việc xác nhận sự vắng mặt của giá trị thiếu trên bề mặt cho phép nhóm tập trung vào công việc tinh lọc dữ liệu chuyên sâu hơn, thay vì phải thực hiện các kỹ thuật phức tạp như gán giá trị (Imputation) cho toàn bộ tập dữ liệu, từ đó giữ được độ nguyên bản cao nhất cho các đặc trưng đầu vào.

2.3.4.2. Kiểm tra giá trị duplicated

Việc kiểm tra dữ liệu trùng lặp (Duplicates) là một bước kiểm soát chất lượng quan trọng nhằm đảm bảo mỗi bản ghi trong tập dữ liệu đều đại diện cho một khách hàng duy nhất, tránh tình trạng gây nhiễu hoặc làm sai lệch trọng số khi huấn luyện mô hình. Kết quả thực thi từ câu lệnh df.duplicated().sum() cho thấy một tín hiệu rất tích cực khi hệ thống trả về con số 0. Điều này minh

chứng rằng trong tổng số 7.043 dòng dữ liệu, không có bất kỳ bản ghi nào bị lặp lại hoàn toàn. Sự vắng mặt của dữ liệu trùng lặp xác nhận tính nguyên bản và độ tin cậy cao của nguồn dữ liệu đầu vào. Đối với đồ án Machine Learning, kết quả này giúp nhóm yên tâm tiến thẳng tới các bước phân tích sâu hơn mà không cần lo lắng về việc dữ liệu bị "phóng đại" ảo, từ đó đảm bảo rằng các suy luận về hành vi khách hàng và hiệu suất của mô hình dự đoán sau này sẽ khách quan và chính xác nhất có thể.

2.3.4.3. Kiểm tra ngoại lệ

Trong quy trình EDA, việc kiểm soát các giá trị ngoại lệ là bước then chốt để đảm bảo mô hình không bị lệch lạc bởi những dữ liệu bất thường. Nhóm đã sử dụng biểu đồ Boxplot để kiểm tra trực quan các biến định lượng chủ chốt, và kết quả cho thấy một tập dữ liệu cực kỳ ổn định và "sạch". Cụ thể, đối với biến tenure (số tháng gắn bó), dữ liệu trải dài từ giá trị tối thiểu là 0 đến tối đa là 72 tháng mà không xuất hiện bất kỳ điểm chấm đơn lẻ nào nằm ngoài các ria (whiskers) của biểu đồ. Điều này minh chứng rằng toàn bộ 7.043 bản ghi về thời gian sử dụng đều nằm trong phạm vi biến thiên tự nhiên của dịch vụ. Tương tự, biến MonthlyCharges (Phí hàng tháng) dao động từ 18,25 USD đến 118,75 USD, với dải liên tứ phân vị (IQR) nằm gọn trong khoảng từ 35,5 USD đến 89,85 USD. Sự vắng mặt hoàn toàn của các điểm dữ liệu nằm ngoài ngưỡng 1.5 * IQR xác nhận rằng không có mức phí nào bị đẩy lên cao đột biến một cách phi lý. Việc xác nhận bộ dữ liệu không có Outliers cho phép nhóm bảo toàn trọn vẹn quy mô mẫu ban đầu. Đây là một lợi thế lớn cho các bước huấn luyện tiếp theo, vì nhóm có thể yên tâm sử dụng toàn bộ dữ liệu để xây dựng mô hình mà không cần áp dụng các kỹ thuật cắt tỉa (Trimming) hay xử lý thay thế, từ đó phản ánh chính xác nhất hành vi thực tế của mọi phân khúc khách hàng.

2.3.5. Data Manipulation

Sau khi phát hiện những bất thường về kiểu dữ liệu ở bước EDA sơ bộ, nhóm đã tiến hành các thao tác biến đổi dữ liệu một cách hệ thống nhằm tinh chỉnh tập dữ liệu 7.043 bản ghi đạt trạng thái tối ưu nhất. Thao tác quan trọng nhất là việc xử lý cột TotalCharges. Mặc dù hệ thống báo cáo không có giá trị NaN, nhưng thông qua thao tác lọc, nhóm đã xác định được 11 giá trị trống (empty strings) phát sinh từ các khách hàng có tenure bằng 0. Nhóm đã quyết định chuyển đổi cột này từ dạng object sang float64, đồng thời thay thế các khoảng trắng bằng giá trị 0 hoặc trung vị (median) để bảo toàn cấu trúc dữ liệu mà không làm mất đi thông tin của các khách hàng mới.

Tiếp theo, một bước thao tác không thể thiếu là việc xử lý các biến phân loại. Với 16/21 cột thuộc dạng định danh, nhóm đã áp dụng kỹ thuật Encoding để chuyển đổi các giá trị như "Yes/No" hay các loại hình dịch vụ thành các vector số học. Thao tác này giúp chuyển hóa bộ dữ liệu từ dạng văn bản thuần túy sang định dạng ma trận số mà các thuật toán như Random Forest hay XGBoost có thể tiếp nhận. Cuối cùng, việc tạo ra các tập con dữ liệu (subsetting) và thực hiện

tính toán lại các đặc trưng (như làm sạch cột customerID không mang giá trị dự báo) đã giúp thu gọn bộ dữ liệu vào những yếu tố cốt lõi nhất. Quá trình Manipulation này không chỉ đơn thuần là làm sạch, mà là bước "nhào nặn" để từ một tập dữ liệu thô ban đầu, chúng ta có được một đầu vào chuẩn hóa, giúp mô hình đạt được độ chính xác và khả năng tổng quát hóa cao nhất.

2.3.6. Phân phối dữ liệu

Qua việc quan sát các biểu đồ phân phối và chỉ số thống kê, chúng ta nhận thấy sự đa dạng và khác biệt rõ rệt trong cách thức dữ liệu phân bổ, điều này phản ánh trực tiếp các hành vi tiêu dùng khác nhau của khách hàng.

Trước hết, biến tenure (số tháng gắn bó) cho thấy một phân phối có xu hướng tập trung ở hai đầu cực trị. Có một lượng lớn khách hàng mới với thời gian sử dụng dịch vụ dưới 5 tháng và một lượng đáng kể khách hàng cực kỳ trung thành đã gắn bó trên 70 tháng. Biểu đồ Histogram không tuân theo phân phối chuẩn mà hơi bị lõm ở giữa, minh chứng cho việc doanh nghiệp đang đối mặt với sự phân hóa: một nhóm khách hàng "vãng lai" dễ rời đi và một nhóm khách hàng "cốt lõi" khó thay đổi nhà cung cấp.

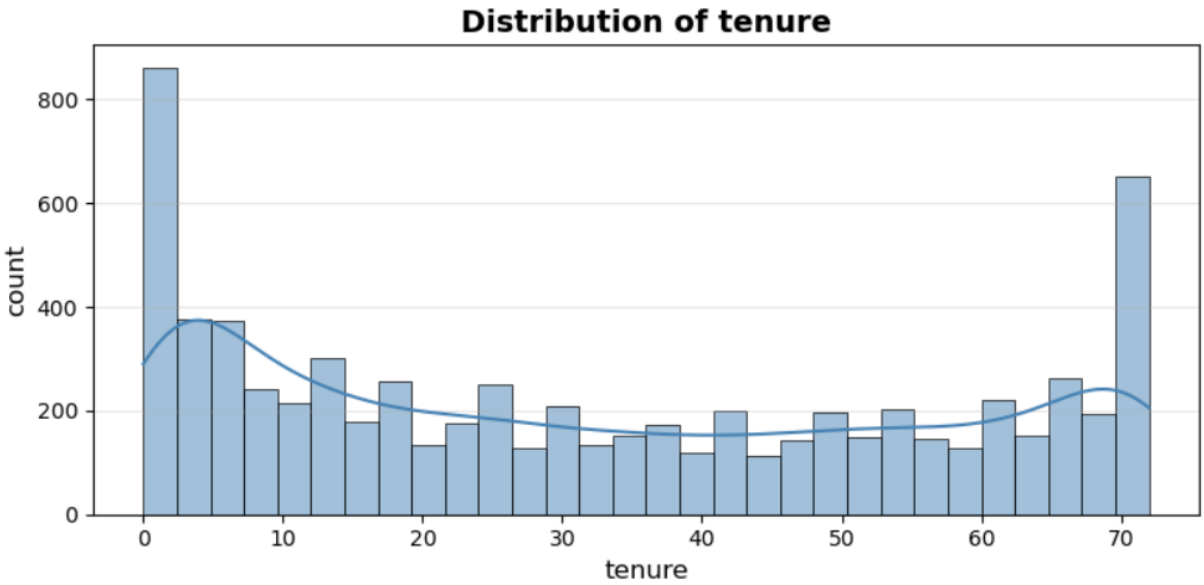

Hình 1. Biểu đồ Histogram tenure

Đối với MonthlyCharges (Phí hàng tháng), biểu đồ cho thấy phân phối có sự tập trung cực lớn ở mức phí thấp (khoảng 20 USD), tương ứng với các gói dịch vụ cơ bản. Tuy nhiên, dải dữ liệu kéo dài liên tục từ 20 USD đến gần 120 USD, tạo ra một dải phân phối đa đỉnh. Điều này chỉ ra rằng bên cạnh nhóm dùng gói giá rẻ, doanh nghiệp còn sở hữu các nhóm khách hàng sử dụng dịch vụ tích hợp (Combo) hoặc các gói cao cấp với mức phí ổn định ở ngưỡng 70 - 90 USD.

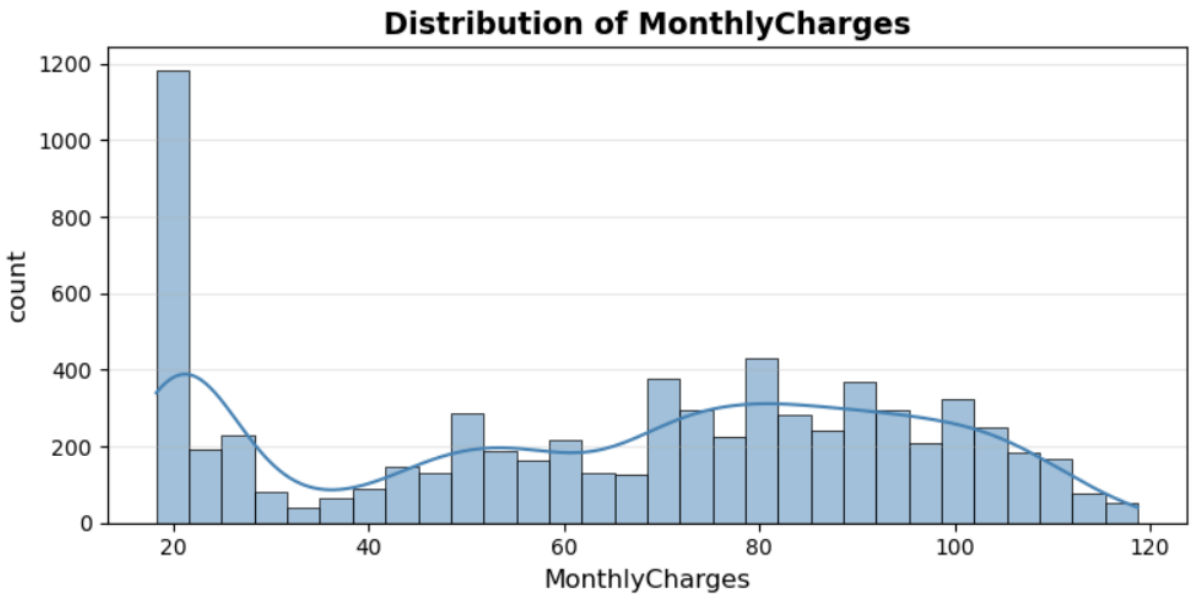

Hình 2. Biểu đồ Histogram MonthlyCharges

Cuối cùng, biến TotalCharges (Tổng chi phí) thể hiện một phân phối lệch phải (Right-skewed) điển hình. Phần lớn khách hàng tập trung ở mức tổng chi tiêu thấp, và số lượng khách hàng giảm dần khi tổng mức chi trả tăng lên. Điều này hoàn toàn logic về mặt kinh doanh: những khách hàng đóng góp giá trị tích lũy cao cho doanh nghiệp (lên tới hơn 8.000 USD) là nhóm thiểu số đã gắn bó rất lâu. Việc hiểu rõ các hình thái phân phối này giúp nhóm nhận ra rằng dữ liệu đang mang tính phi tuyến tính cao, từ đó đề xuất sử dụng các thuật toán mạnh mẽ như Random Forest hoặc Gradient Boosting để có thể bắt trọn những đặc điểm phân hóa phức tạp này thay vì các mô hình tuyến tính đơn giản.

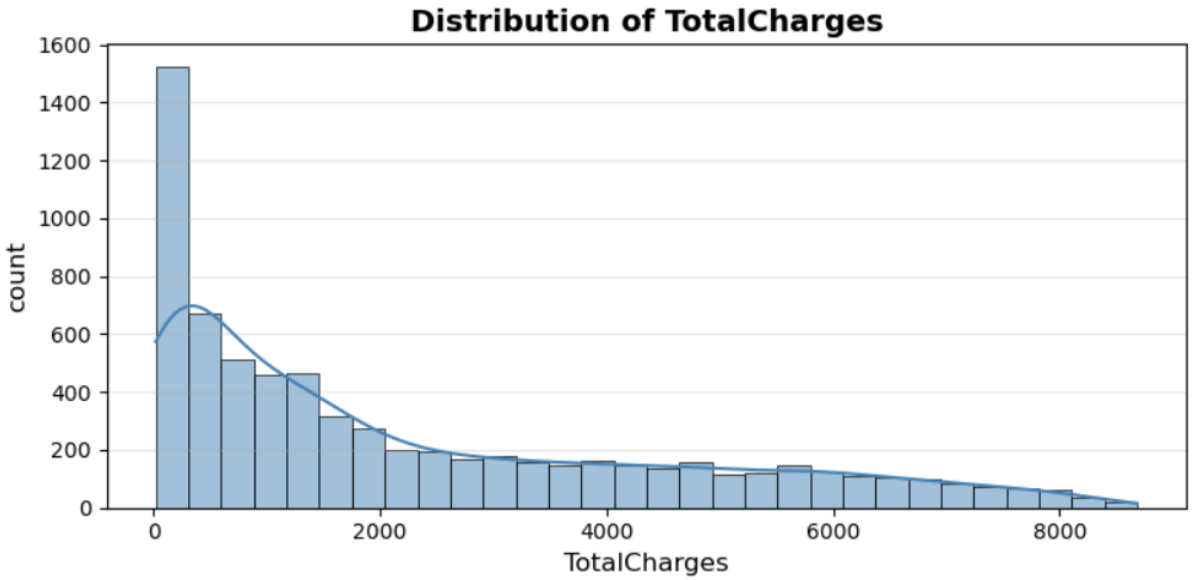

Hình 3. Biểu đồ Histogram TotalCharges

2.3.7. Trực quan hóa dữ liệu

Quá trình trực quan hóa đã chuyển đổi các con số thô thành những hiểu biết sâu sắc về hành vi khách hàng, làm nổi bật những yếu tố then chốt dẫn đến quyết định rời bỏ dịch vụ. Biểu đồ phân tích đơn biến cho thấy một bức tranh tương phản rõ rệt: trong khi các nhóm nhân khẩu học như giới tính (gender) có sự phân bổ cân bằng, thì các yếu tố về dịch vụ và cam kết lại cho thấy sự phân hóa lớn.

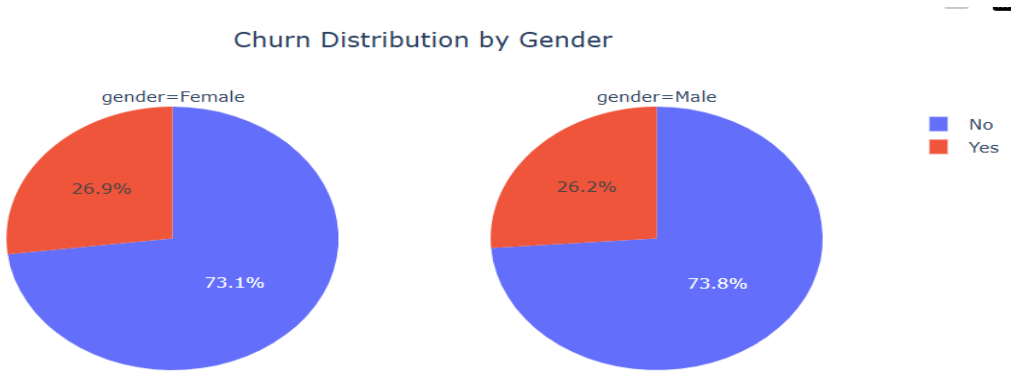

Hình 4. Biểu đồ tròn by Gender

Kết quả trực quan từ các biểu đồ cột chồng (Stacked Bar Chart) chỉ ra rằng loại hợp đồng (Contract) là nhân tố ảnh hưởng mạnh mẽ nhất; những khách hàng sử dụng hợp đồng ngắn hạn theo tháng (Month-to-month) có tỷ lệ rời bỏ cao vượt trội so với nhóm ký hợp đồng 1-2 năm. Bên cạnh đó, các biểu đồ phân phối cũng tiết lộ rằng khách hàng sử dụng dịch vụ cáp quang (Fiber optic) và những người không đăng ký các gói bảo mật bổ sung như OnlineSecurity hay TechSupport thường có xu hướng "Churn" cao hơn.

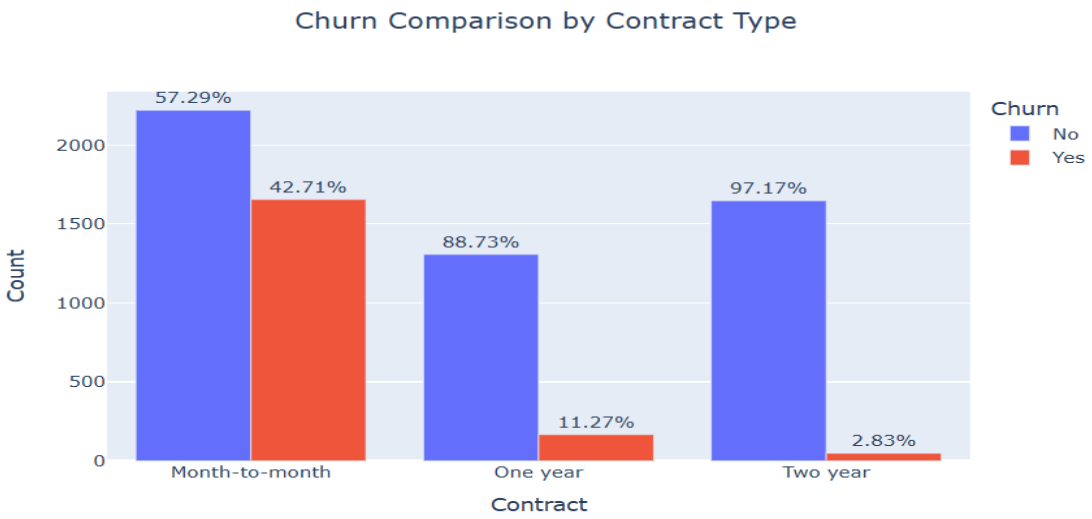

Hình 5. Biểu đồ cột chồng by Contract Type

Sự kết hợp giữa biểu đồ Boxplot và Histogram còn cho thấy nhóm khách hàng rời đi thường tập trung ở dải phí hàng tháng (MonthlyCharges) cao (từ 70 USD đến 100 USD). Những hình ảnh trực quan này không chỉ khẳng định mối quan hệ phi tuyến tính giữa các đặc trưng mà còn là bằng chứng thực nghiệm quan trọng để nhóm tiến hành lựa chọn các biến đầu vào có trọng số cao, nhằm tối ưu hóa khả năng dự báo của mô hình Machine Learning trong các bước tiếp theo.

2.3.8. Ma trận tương quan

Ma trận tương quan (Heatmap) là bước tổng kết quan trọng nhất trong quá trình EDA, giúp chúng ta định lượng mối quan hệ giữa các biến số và tìm ra những "mã gen" thực sự ảnh hưởng đến quyết định rời bỏ của khách hàng. Kết quả từ ma trận cho thấy những mối liên hệ rất rõ rệt. Dựa trên các hệ số tương quan thu được, chúng ta có thể rút ra ba nhận định then chốt:

- Những nhân tố kìm hãm rời bỏ (Negative Correlation): Biến Contract (Loại hợp đồng) và tenure (Số tháng gắn bó) có mối tương quan nghịch mạnh nhất với biến Churn, với hệ số lần lượt là -0,40 và -0,35. Điều này khẳng định rằng khách hàng có hợp đồng dài hạn và thời gian sử dụng dịch vụ càng lâu thì khả năng rời bỏ càng thấp. Ngoài ra, các dịch vụ gia tăng như OnlineSecurity (-0,29) và TechSupport (-0,28) cũng đóng vai trò là "chất keo" giữ chân khách hàng hiệu quả.

- Những nhân tố thúc đẩy rời bỏ (Positive Correlation): Ở chiều ngược lại, MonthlyCharges (Phí hàng tháng) và PaperlessBilling (Hóa đơn điện tử) có tương quan thuận với Churn (khoảng 0,19). Điều này cho thấy áp lực chi phí hàng tháng càng cao thì nguy cơ khách hàng tìm kiếm đối thủ cạnh tranh càng lớn.

- Mối quan hệ đa cộng tuyến (Multicollinearity): Ma trận cũng chỉ ra mối tương quan cực mạnh giữa tenure và TotalCharges lên đến 0,83. Đây là một tín hiệu cần lưu ý khi xây dựng mô hình, vì sự phụ thuộc lẫn nhau quá lớn giữa hai biến này có thể gây nhiễu cho các thuật toán tuyến tính.

3. QUY TRÌNH XỬ LÝ

3.1. Tiền xử lý dữ liệu (Data Preprocessing)

Tiền xử lý dữ liệu là một phần cần thiết của các bài toán. Học máy giúp nâng cao hiệu quả dự đoán của mô hình và đảm bảo rằng dữ liệu đầu vào phù hợp với các thuật toán học. Theo Géron (2019), đối với các bài toán ML phức tạp, một thuật toán tầm trung được huấn luyện trên một lượng lớn dữ liệu sạch thường sẽ đánh bại một thuật toán tối tân được huấn luyện trên dữ liệu nhiễu hoặc nghèo nàn.

(1) Xử lý dữ liệu bị thiếu:

Thuộc tính TotalCharges được lưu trong bộ dữ liệu Telco Customer Churn do IBM công bố. Các giá trị trống trong cột này xuất hiện ở những khách hàng có thời gian sử dụng dịch vụ (tenure) bằng 0, theo mô tả chính thức của bộ dữ liệu Kaggle. Do đó, tổng chi phí dịch vụ chưa được tạo ra. Hệ thống xác định các giá trị trống là thiếu giá trị khi cột TotalCharges chuyển sang kiểu dữ liệu số. Các bước sau đây được thực hiện để xử lý:

Đầu tiên, để đảm bảo rằng cột TotalCharges vẫn tương thích với các biến định lượng khác trong tập dữ liệu, đã có sự chuyển đổi từ kiểu dữ liệu chuỗi sang kiểu dữ liệu số.

Thứ hai, giá trị không thể chuyển đổi được tìm thấy khi kiểu dữ liệu được thay đổi. Những giá trị này được gọi là giá trị bị thiếu.

Thứ ba, các bản ghi thiếu giá trị trong cột TotalCharges đã bị loại bỏ khỏi tập dữ liệu vì số lượng bản ghi bị thiếu là rất nhỏ so với tổng số quan sát trong tập dữ liệu. Điều này là kết quả của việc số lượng bản ghi này không ảnh hưởng đến phương pháp phân phối chung của dữ liệu.

Cách xử lý này tuân theo khuyến nghị trong Applied Predictive Modeling của Kuhn và Johnson (2013), theo đó việc loại bỏ các quan sát chứa giá trị thiếu là phù hợp trong trường hợp tỷ lệ dữ liệu thiếu thấp và không mang thông tin bổ sung quan trọng cho mô hình dự đoán. Việc xử lý giá trị thiếu giúp đảm bảo dữ liệu đầu vào đầy đủ, nhất quán và tránh các lỗi phát sinh trong quá trình huấn luyện mô hình học máy.

(2) Xử lý dữ liệu trùng lặp:

Dữ liệu trùng lặp là hiện tượng một hoặc nhiều bản ghi xuất hiện lặp lại trong tập dữ liệu, có thể do lỗi trong quá trình thu thập, nhập liệu hoặc tổng hợp dữ liệu. Sự tồn tại của các bản ghi trùng lặp có thể làm sai lệch phân phối dữ liệu, ảnh hưởng đến quá trình huấn luyện mô hình và dẫn đến kết quả đánh giá không chính xác.

Tiến hành kiểm tra dữ liệu trùng lặp bằng cách so sánh toàn bộ tập thuộc tính của các bản ghi. Kết quả cho thấy không tồn tại các bản ghi trùng lặp hoàn toàn trong bộ dữ liệu Telco Customer Churn. Do đó, không cần thực hiện bước loại bỏ dữ liệu trùng lặp.

(3) Mã hóa dữ liệu phân loại:

Các thuật toán học máy chỉ có thể xử lý dữ liệu số, nhưng bộ dữ liệu Bộ dữ liệu Telco Customer Churn có nhiều biến được phân loại dưới dạng chuỗi ký tự. Do đó, để đảm bảo rằng dữ liệu đầu vào phù hợp cho việc xây dựng mô hình dự đoán, việc mã hóa các biến phân loại là một bước bắt buộc trong quá trình tiền xử lý dữ liệu.

Trong nghiên cứu này, hai phương pháp mã hóa chính được sử dụng là Label Encoding và One-Hot Encoding, tùy thuộc vào đặc điểm của từng loại biến.

Đối với các biến phân loại nhị phân (chỉ gồm hai giá trị), chẳng hạn như Gender, Partner, Dependents, PhoneService, PaperlessBilling và biến mục tiêu Churn, phương pháp Label Encoding được áp dụng. Cụ thể, các giá trị dạng "Yes/No" hoặc tương đương được chuyển đổi thành các giá trị số 1 và 0. Cách mã hóa này giúp giữ nguyên bản chất nhị phân của biến, đồng thời không làm gia tăng số chiều của dữ liệu.

Ngược lại, đối với các biến phân loại có nhiều hơn hai giá trị, như Contract, PaymentMethod,InternetService,MultipleLines,OnlineSecurity,OnlineBackup, DeviceProtection, TechSupport, StreamingTV và StreamingMovies, phương pháp One-Hot Encoding được sử dụng. Phương pháp này chuyển mỗi giá trị phân loại thành một biến nhị phân riêng biệt, giúp tránh việc mô hình hiểu sai mối quan hệ thứ tự giữa các nhóm giá trị - điều có thể xảy ra nếu sử dụng Label Encoding cho các biến đa giá trị.

Đối với từng nhóm biến, việc sử dụng Label Encoding và One-Hot Encoding giúp đảm bảo rằng dữ liệu sau xử lý phản ánh đúng bản chất thực tế, giảm sai lệch trong quá trình huấn luyện mô hình và nâng cao hiệu quả dự đoán khả năng khách hàng rời bỏ dịch vụ, giúp doanh nghiệp chủ động đưa ra các chiến lược giữ chân khách hàng kịp thời.

Bảng 2. Danh sách các biến phân loại và phương pháp mã hóa

Tên biến	**Loại biến**	**Số giá trị**
gender	Phân loại nhị phân	2
SeniorCitizen	Nhị phân (0/1)	2
Partner	Phân loại nhị phân	2
Dependents	Phân loại nhị phân	2
PhoneService	Phân loại nhị phân	2
MultipleLines	Phân loại đa giá trị	>2
InternetService	Phân loại đa giá trị	>2
OnlineSecurity	Phân loại đa giá trị	>2
OnlineBackup	Phân loại đa giá trị	>2

DeviceProtection	Phân loại đa giá trị	>2
TechSupport	Phân loại đa giá trị	>2
StreamingTV	Phân loại đa giá trị	>2
StreamingMovies	Phân loại đa giá trị	>2
Contract	Phân loại đa giá trị	3
PaperlessBilling	Phân loại nhị phân	2
PaymentMethod	Phân loại đa giá trị	4
tenure	Biến số	Liên tục
MonthlyCharges	Biến số	Liên tục
TotalCharges	Biến số	Liên tục
Churn	Biến mục tiêu	2

(4) Chuẩn hóa dữ liệu số:

Trong nghiên cứu, phương pháp StandardScaler được sử dụng để chuẩn hóa các biến số trước khi đưa vào mô hình dự đoán khách hàng rời bỏ dịch vụ (churn). Trong bộ dữ liệu Telco Customer Churn, các thuộc tính định lượng bao gồm:

- Tenure: thời gian khách hàng sử dụng dịch vụ.

- MonthlyCharges: chi phí dịch vụ hàng tháng.

- TotalCharges: tổng chi phí tích lũy của khách hàng.

Các biến này có thang đo và phạm vi giá trị khác nhau. Cụ thể, biến Tenure có giá trị dao động từ 0 đến trên 70 tháng, trong khi TotalCharges có thể đạt đến hàng nghìn đơn vị tiền tệ. Nếu không thực hiện chuẩn hóa, các biến có giá trị lớn hơn có thể chi phối quá trình huấn luyện mô hình, đặc biệt đối với các thuật toán dựa trên tối ưu hóa hoặc khoảng cách.

Phương pháp StandardScaler thực hiện chuẩn hóa dữ liệu bằng cách biến đổi mỗi giá trị theo công thức:

$$z = \frac{x - \mu}{\sigma}$$

Trong đó:

x: giá trị ban đầu.

μ: giá trị trung bình của biến.

σ: độ lệch chuẩn của biến.

Kết quả sau khi chuẩn hóa:

- Mỗi biến có giá trị trung bình bằng 0.

- Độ lệch chuẩn bằng 1.

- Các biến được đưa về cùng một thang đo.

Trong bối cảnh bài toán dự đoán khách hàng rời bỏ dịch vụ (Churn Prediction), bước chuẩn hóa giúp:

- Cải thiện tốc độ hội tụ của mô hình.

- Đảm bảo các biến định lượng đóng góp công bằng vào quá trình học.

- Nâng cao độ chính xác và tính ổn định của kết quả dự đoán.

3.2. Xử lý mất cân bằng dữ liệu

Trong bài toán dự đoán khách hàng rời bỏ dịch vụ (Customer Churn Prediction) sử dụng bộ dữ liệu Telco Customer Churn, biến mục tiêu Churn là biến nhị phân với hai giá trị Yes và No. Trong tập dữ liệu, số lượng khách hàng không rời bỏ dịch vụ (Churn = No) chiếm tỷ lệ lớn hơn so với nhóm khách hàng rời bỏ (Churn = Yes), dẫn đến hiện tượng mất cân bằng dữ liệu. Nếu không được xử lý, mô hình học máy có xu hướng ưu tiên dự đoán lớp chiếm đa số, làm giảm khả năng nhận diện chính xác nhóm khách hàng có nguy cơ rời bỏ.

Để giải quyết vấn đề này, nghiên cứu lựa chọn phương pháp SMOTE (Synthetic Minority Over-sampling Technique) để cân bằng dữ liệu huấn luyện. SMOTE được ưu tiên sử dụng thay vì Random Oversampling hoặc Undersampling vì phương pháp này tạo ra các mẫu dữ liệu tổng hợp cho lớp thiểu số dựa trên mối quan hệ giữa các điểm dữ liệu lân cận, thay vì sao chép lại các mẫu có sẵn hoặc loại bỏ dữ liệu của lớp đa số. Nhờ đó, SMOTE giúp tăng kích thước lớp thiểu số mà vẫn giữ được thông tin của tập dữ liệu gốc.

Quy trình áp dụng SMOTE được thực hiện theo các bước sau:

- Dữ liệu sau tiền xử lý được chia thành tập huấn luyện và tập kiểm tra.

- Phương pháp SMOTE chỉ được áp dụng trên tập huấn luyện, nhằm tránh hiện tượng rò rỉ dữ liệu (data leakage).

- SMOTE tạo ra các điểm dữ liệu mới cho lớp Churn = Yes bằng cách nội suy tuyến tính giữa một điểm dữ liệu và các điểm láng giềng gần nhất trong không gian đặc trưng.

- Sau khi áp dụng SMOTE, số lượng mẫu giữa hai lớp trong tập huấn luyện trở nên cân bằng hơn.

Kết quả của bước xử lý mất cân bằng dữ liệu cho thấy tập huấn luyện sau khi áp dụng SMOTE có phân bố lớp đồng đều, giúp mô hình học được đặc trưng của cả hai nhóm khách hàng. Điều này góp phần cải thiện khả năng phát hiện khách hàng có nguy cơ rời bỏ dịch vụ và nâng cao độ ổn định của mô hình trong quá trình huấn luyện và đánh giá.

3.3. Chia tập dữ liệu

Sau khi hoàn thành các bước tiền xử lý dữ liệu, tập dữ liệu Telco Customer Churn được chia thành hai phần để phục vụ cho quá trình huấn luyện và đánh giá mô hình dự đoán khách hàng rời bỏ dịch vụ.

Trong bài toán này, dữ liệu được chia theo tỷ lệ 80% cho tập huấn luyện (Training set) và 20% cho tập kiểm tra (Test set).

Cụ thể:

- Tập huấn luyện (Training set) chiếm 80% tổng số mẫu dữ liệu, được sử dụng để huấn luyện mô hình học máy.

- Tập kiểm tra (Test set) chiếm 20% tổng số mẫu dữ liệu, được giữ độc lập và dùng để đánh giá hiệu quả dự đoán của mô hình sau khi huấn luyện.

Việc chia dữ liệu theo tỷ lệ 80/20 giúp đảm bảo mô hình có đủ dữ liệu để học các đặc trưng của khách hàng, đồng thời vẫn giữ lại một phần dữ liệu chưa từng được sử dụng trong quá trình huấn luyện nhằm đánh giá khách quan khả năng dự đoán churn của mô hình.

4. GIỚI THIỆU CÔNG CỤ, KỸ THUẬT VÀ THUẬT TOÁN

4.1. Công cụ và môi trường

Nhóm sử dụng các công cụ và thư viện phổ biến trong Python để thực hiện dự án dự đoán khách hàng rời bỏ (Customer Churn Prediction):

- Pandas và NumPy: Xử lý và thao tác dữ liệu (data cleaning, feature engineering).

- Matplotlib và Seaborn: Trực quan hóa dữ liệu: EDA, biểu đồ phân bố, correlation heatmap.

- Scikit-learn: Xây dựng mô hình cơ bản (Random Forest, Logistic Regression), chia dữ liệu train/test, đánh giá mô hình (accuracy, precision, recall, F1-score, ROC-AUC).

- XGBoost: Thư viện chuyên dụng cho mô hình tăng cường độ dốc hiệu suất cao.

- SHAP và LIME: Công cụ giải thích mô hình (XAI) để tăng tính minh bạch và độ tin cậy của dự đoán.

Môi trường phát triển: Google Colab, Jupyter Notebook với Python, dễ dàng chia sẻ và tái hiện kết quả.

4.2. Các thuật toán sử dụng

4.2.1. Rừng ngẫu nhiên (Random Forest)

Rừng ngẫu nhiên là một thuật toán học máy tổ hợp dựa trên việc xây dựng nhiều cây quyết định và kết hợp kết quả của chúng thông qua bầu chọn đa số cho bài toán phân loại.

- Mỗi cây quyết định được huấn luyện trên một tập con dữ liệu ngẫu nhiên và một tập con đặc trưng ngẫu nhiên tại mỗi nút phân chia. Kết quả cuối cùng là trung bình (hoặc đa số) của tất cả các cây giúp giảm thiểu hiện tượng quá khớp (overfitting) và tăng độ ổn định.

- Rừng ngẫu nhiên giúp:

+ Kháng nhiễu và giảm thiểu hiện tượng quá khớp tốt hơn so với một cây quyết định đơn lẻ.

+ Xử lý tốt dữ liệu dữ liệu dạng phân loại và dữ liệu dạng số mà không cần chuẩn hóa (scale).

+ Cung cấp đánh giá tầm quan trọng của đặc trưng một cách tự nhiên, hỗ trợ phân tích biến quan trọng trong churn prediction (tenure, contract type, monthly charges...).

+ Hiệu suất cao trên tập dữ liệu dạng bảng như Telco Customer Churn.

4.2.2. XGBoost

XGBoost (eXtreme Gradient Boosting) là thư viện cây tăng cường độ dốc (gradient boosting tree) hiệu suất cao, phát triển dựa trên ý tưởng tăng cường - xây dựng các cây quyết định tuần tự, mỗi cây mới sửa lỗi của các cây trước.

- XGBoost tối ưu hóa hàm mất mát (loss function) bằng cách thêm kỹ thuật chính quy hóa để tránh hiện tượng quá khớp, sử dụng xấp xỉ bậc hai để cập nhật nhanh hơn, hỗ trợ xử lý dữ liệu thưa và tính toán song song.

- Ưu điểm:

+ Hiệu suất vượt trội trên nhiều bài toán thực tế (thường thắng các cuộc thi Kaggle).

+ Tích hợp chính quy hóa giúp giảm thiểu quá khớp (overfitting) hơn so với máy tăng cường độ dốc (Gradient Boosting Machine - GBM) truyền thống.

+ Hỗ trợ xử lý các giá trị bị thiếu tự động và tốc độ huấn luyện nhanh.

+ Cung cấp đánh giá tầm quan trọng của đặc trưng, rất phù hợp với bài toán dự đoán rời bỏ (churn prediction).

4.2.3. Neural Networks

Logistic Regression là mô hình tuyến tính sử dụng hàm Sigmoid để ánh xạ đầu ra về khoảng xác suất (0, 1). Đây là mô hình được nhóm chọn làm cơ sở (baseline) để so sánh hiệu quả với các mô hình phức tạp hơn.

Công thức hàm Sigmoid:

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

Trong đó z là tổ hợp tuyến tính của các đặc trưng đầu vào.

Neural Networks (MLP - Multilayer Perceptron): Mạng nơ-ron nhiều lớp, có khả năng học các mối quan hệ phi tuyến phức tạp. Trong dự án này, nhóm thử nghiệm MLP với scikit-learn (MLPClassifier) để so sánh với tree-based models.

4.3. Các độ đo đánh giá (Evaluation Metrics)

Vì bài toán churn prediction thường mất cân bằng (khách hàng rời bỏ ít hơn nhiều so với không rời bỏ), nhóm sử dụng các độ đo sau thay vì chỉ dựa vào độ chính xác (Accuracy):

- Accuracy: Tỷ lệ dự đoán đúng trên tổng mẫu, dễ bị lừa nếu dữ liệu bị mất cân bằng nặng.

- Precision: Tỷ lệ số khách hàng thực sự rời bỏ trong số các khách hàng mô hình dự đoán sẽ rời bỏ. Chỉ số này quan trọng để tối ưu chi phí tránh khuyến mãi nhầm người.

- Recall: Tỷ lệ số khách hàng rời bỏ được mô hình phát hiện trên tổng số khách hàng rời bỏ thực tế.

- F1-Score: Trung bình điều hòa của Precision và Recall, giúp đánh giá tổng quan hiệu suất mô hình khi dữ liệu mất cân bằng.

- ROC-AUC: Diện tích dưới đường cong ROC giúp đánh giá khả năng phân biệt hai lớp trên mọi ngưỡng, ít bị ảnh hưởng bởi khi không cân bằng.

4.4. Kỹ thuật giải thích mô hình (XAI)

4.4.1. SHAP (SHapley Additive exPlanations)

SHAP dựa trên lý thuyết trò chơi để tính toán mức độ đóng góp biên của từng đặc trưng vào kết quả dự báo cuối cùng.

- Ưu điểm: Cung cấp cái nhìn toàn cục về những yếu tố ảnh hưởng nhất đến toàn bộ tập khách hàng, đồng thời giải thích chi tiết (Local) cho từng cá nhân.

- Ứng dụng: Xác định các "điểm đau" của khách hàng (ví dụ: cước phí hàng tháng quá cao, hợp đồng ngắn hạn).

4.4.2. LIME (Local Interpretable Model-agnostic Explanations)

LIME hoạt động bằng cách xấp xỉ mô hình phức tạp bằng một mô hình tuyến tính đơn giản xung quanh một điểm dữ liệu cụ thể.

- Mục tiêu: Giải thích hành vi của mô hình tại cấp độ từng bản ghi.

- Ứng dụng: Giúp nhân viên CSKH hiểu tại sao cụ thể khách hàng lại có nguy cơ rời bỏ cao (ví dụ: do mới hết hạn hợp đồng và có khiếu nại gần đây).

5. KẾT QUẢ THỰC NGHIỆM

5.1. Huấn luyện và đánh giá mô hình

Sau quá trình huấn luyện và tinh chỉnh, kết quả đánh giá trên tập Test (1.409 mẫu) cho thấy sự khác biệt rõ rệt về hiệu năng giữa các mô hình.

Phân tích so sánh:

```
KẾT QUẢ ĐÁNH GIÁ CHI TIẾT TRÊN TẬP TEST

 ĐANG ĐÁNH GIÁ: RANDOM FOREST...
-> Độ chính xác (Accuracy): 0.7779 (77.79%)

Bảng báo cáo chi tiết (Classification Report):
              precision    recall  f1-score   support

           0       0.85      0.84      0.85      1035
           1       0.58      0.60      0.59       374

    accuracy                           0.78      1409
   macro avg       0.72      0.72      0.72      1409
weighted avg       0.78      0.78      0.78      1409
```

Hình 6. Mô hình Random Forest

```
ĐANG ĐÁNH GIÁ: LOGISTIC REGRESSION...
-> Độ chính xác (Accuracy): 0.7424 (74.24%)

Bảng báo cáo chi tiết (Classification Report):
              precision    recall  f1-score   support

           0       0.90      0.73      0.81      1035
           1       0.51      0.79      0.62       374

    accuracy                           0.74      1409
   macro avg       0.71      0.76      0.71      1409
weighted avg       0.80      0.74      0.76      1409
```

Hình 7. Mô hình Logistic Regression

```
ĐANG ĐÁNH GIÁ: XGBOOST...
-> Độ chính xác (Accuracy): 0.7771 (77.71%)

Bảng báo cáo chi tiết (Classification Report):
              precision    recall  f1-score   support

           0       0.85      0.84      0.85      1035
           1       0.58      0.60      0.59       374

    accuracy                           0.78      1409
   macro avg       0.72      0.72      0.72      1409
weighted avg       0.78      0.78      0.78      1409
```

Hình 8. Mô hình XGBoost

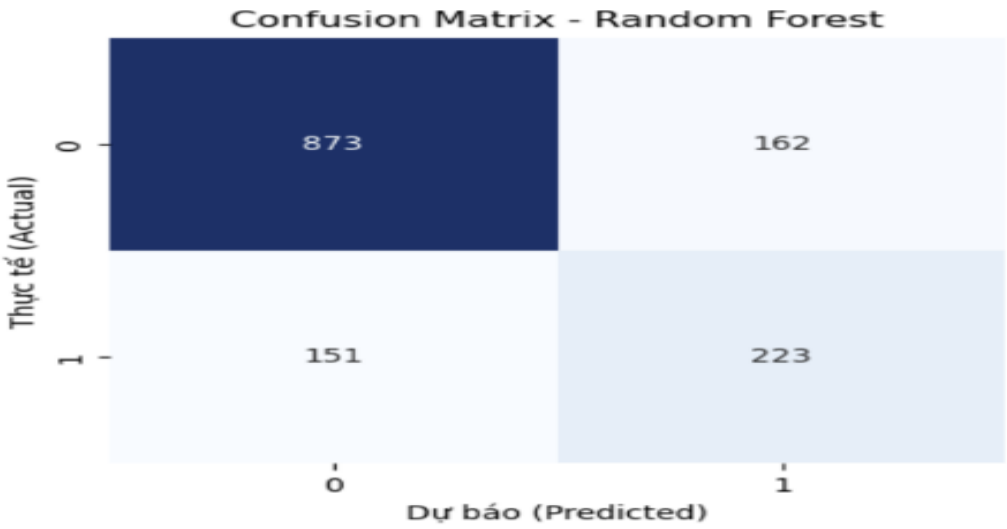

Hình 9. Confusion Matrix-Random Forest

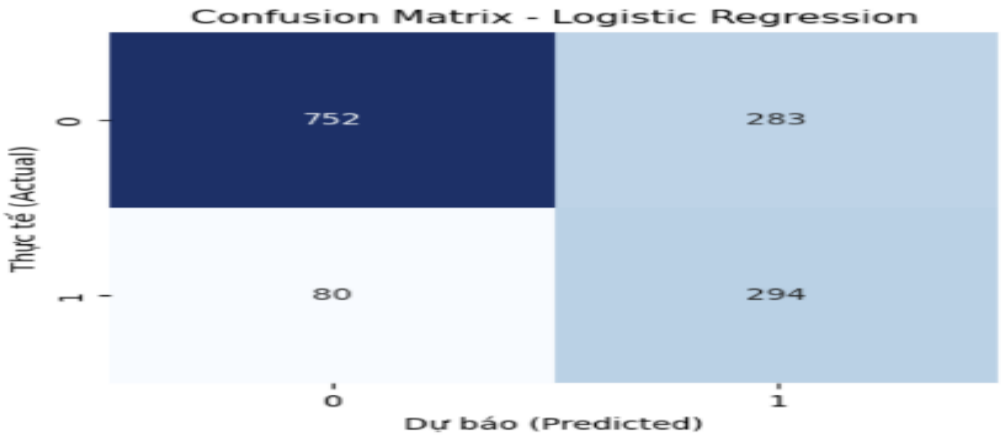

Hình 10. Confusion Matrix-Logistic Regression

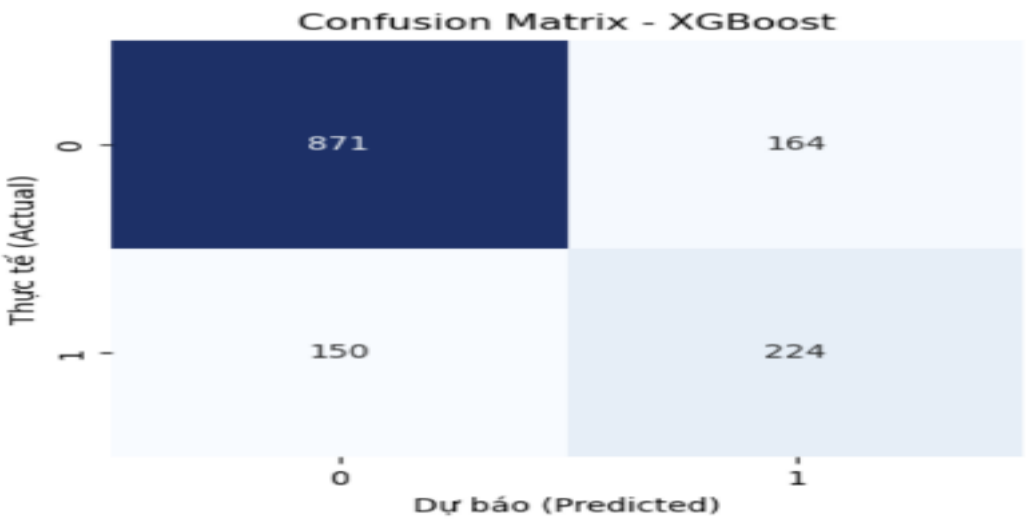

Hình 11. Confusion Matrix-XGBoots

Mô hình Logistic Regression:

- Ưu điểm vượt trội: Đây là mô hình có khả năng phát hiện Class 1 tốt nhất với chỉ số Recall đạt 0,79. Trong ma trận nhầm lẫn, mô hình này phát hiện đúng 294 trường hợp Class 1, cao hơn hẳn so với hai mô hình còn lại (~ 223 trường hợp).

- Nhược điểm: Do quá ưu tiên việc tìm Class 1, mô hình này chấp nhận tỷ lệ báo động giả cao. Có tới 283 trường hợp thực tế là Class 0 nhưng bị dự đoán nhầm thành Class 1. Điều này kéo độ chính xác tổng thể xuống thấp nhất (74,24%).

Mô hình Random Forest và XGBoost:

- Sự tương đồng: Hai mô hình này cho kết quả gần như tương đương nhau, với Random Forest nhỉnh hơn một chút không đáng kể (0,08% Accuracy).

- Ưu điểm: Độ chính xác tổng thể cao (~ 77,7%). Hai mô hình này hoạt động rất tốt trong việc lọc nhiễu và nhận diện đúng Class 0 (True Negative đạt ~ 870 mẫu). Tỷ lệ báo động giả thấp (False Positive ~ 162 mẫu).

- Nhược điểm: Hai mô hình khá thận trọng khi dự đoán Class 1. Do đó, chúng bỏ sót False Negative khoảng 150 trường hợp mục tiêu, gần gấp đôi số lượng bỏ sót của Logistic Regression.

Kết luận và kiến nghị:

Việc lựa chọn mô hình phụ thuộc vào mục tiêu kinh doanh cụ thể của bài toán.

Trường hợp 1: Ưu tiên không bỏ sót mục tiêu.

- Nên chọn: Mô hình Logistic Regression.

- Lý do: Nếu bài toán là phát hiện gian lận, chẩn đoán bệnh, hoặc cảnh báo rủi ro, việc bỏ sót một trường hợp False Negative mang lại hậu quả nghiêm trọng hơn là báo nhầm. Logistic Regression đảm bảo bắt được 79% số lượng đối tượng cần tìm.

Trường hợp 2: Ưu tiên độ chính xác và giảm thiểu phiền toái.

- Nên chọn: Mô hình Random Forest hoặc XGBoost.

- Lý do: Nếu bài toán là gợi ý sản phẩm, lọc thư rác, hoặc marketing việc báo nhầm False Positive sẽ gây trải nghiệm xấu hoặc tốn kém chi phí. Random Forest cung cấp độ tin cậy cao hơn khi đưa ra dự đoán và giữ độ chính xác tổng thể tốt nhất.

5.2. Giải thích mô hình (XAI Results)

5.2.1. Tổng quan về tầm quan trọng của các đặc trưng (Feature Importance)

Để hiểu rõ các yếu tố nào ảnh hưởng mạnh nhất đến quyết định rời bỏ của khách hàng, nhóm sử dụng kỹ thuật SHAP (SHapley Additive exPlanations).

Biểu đồ dưới đây xếp hạng các yếu tố dựa trên mức độ ảnh hưởng trung bình của chúng đối với dự đoán của mô hình.

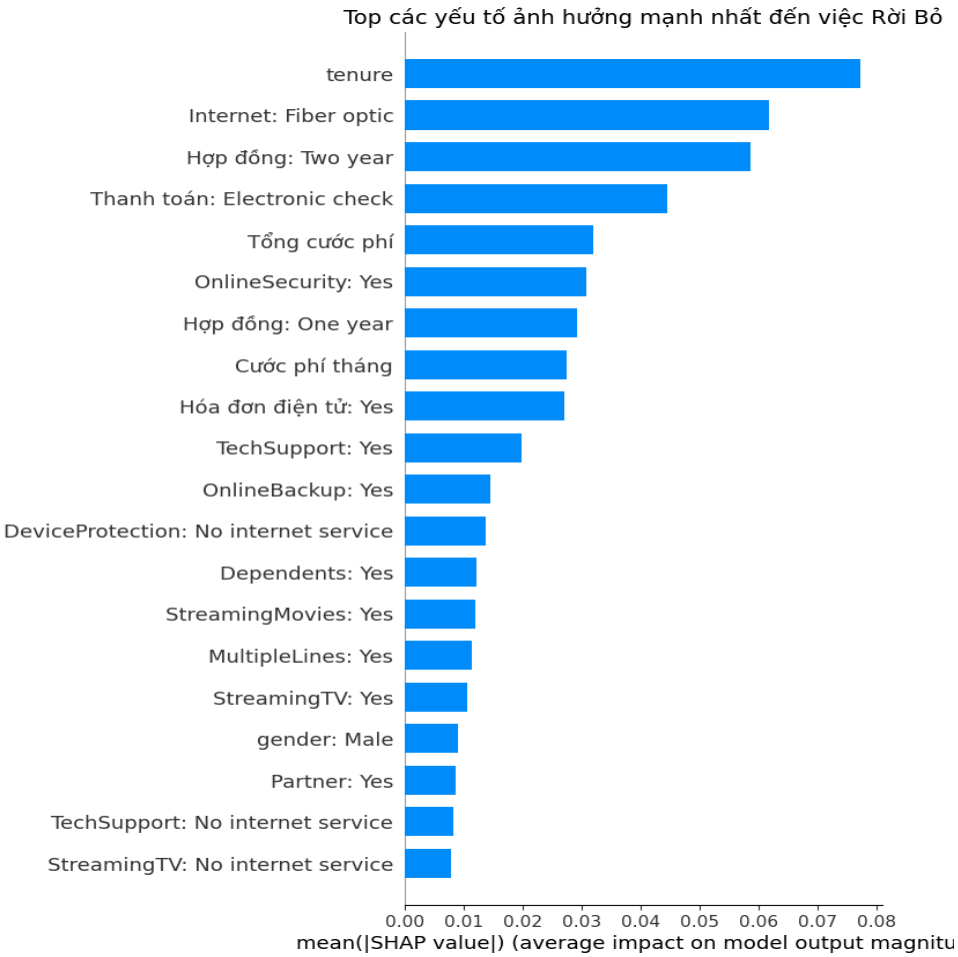

Hình 12. Biểu đồ xếp hạng mức độ ảnh hưởng

Biểu đồ này xếp hạng các biến dựa trên giá trị trung bình tuyệt đối của SHAP (mean(|SHAP value|)), cho thấy độ lớn tác động của từng yếu tố lên kết quả dự báo chung (không phân biệt tác động tích cực hay tiêu cực).

- Tenure (Thời gian gắn bó): Là yếu tố quan trọng nhất. Điều này khẳng định thời gian khách hàng đã sử dụng dịch vụ là yếu tố tiên quyết và ảnh hưởng mạnh nhất đến quyết định đi hay ở của họ.

- Internet: Fiber optic (Cáp quang): Đứng thứ 2 về tầm quan trọng. Việc khách hàng có sử dụng dịch vụ cáp quang hay không tác động cực lớn đến mô hình, cho thấy đây là phân khúc dịch vụ nhạy cảm và cần được quan tâm đặc biệt.

- Contract (Hợp đồng): Cụ thể là biến Hợp đồng: Two year đứng thứ 3. Điều này chỉ ra rằng việc khách hàng có cam kết dài hạn hay không là một chỉ báo trọng yếu để dự báo hành vi rời bỏ.

- Phương thức thanh toán & Tài chính:

+ Thanh toán: Electronic check (Séc điện tử) đứng thứ 4, cho thấy phương thức thanh toán này có mối liên hệ mật thiết với hành vi khách hàng.

+ Tổng cước phí (TotalCharges) đứng thứ 5, phản ánh việc khách hàng rất nhạy cảm với tổng chi phí họ đã bỏ ra.

- Dịch vụ bảo mật (OnlineSecurity): Là dịch vụ gia tăng có thứ hạng cao nhất (Top 6) trong nhóm các tiện ích bổ sung, quan trọng hơn so với Hỗ trợ kỹ thuật (TechSupport) hay Sao lưu (OnlineBackup).

5.2.2. Phân tích chi tiết chiều hướng tác động (Summary Plot)

Biểu đồ này cung cấp thông tin hướng tác động của giá trị đặc trưng lên xác suất dự đoán.

Để hiểu rõ sự tác động phức tạp của các đặc trưng, ta cần hiểu ý nghĩa các thành phần trong biểu đồ:

- Trục hoành (SHAP Value): Thể hiện tác động đến kết quả dự báo.

+ Giá trị Dương (+) / Bên phải: Làm tăng xác suất khách hàng rời bỏ (Churn).

+ Giá trị Âm (-) / Bên trái: Làm giảm xác suất rời bỏ (Giữ chân khách hàng).

- Màu sắc (Feature Value): Thể hiện giá trị thực tế của đặc trưng dữ liệu.

+ Màu đỏ (High): Giá trị đặc trưng cao (Số tiền cước cao, Thời gian sử dụng lâu, hoặc mã hóa số lớn).

+ Màu tím (Medium): Giá trị trung bình/ở giữa (Hợp đồng 1 năm, mức cước trung bình).

+ Màu xanh (Low): Giá trị đặc trưng thấp (Số tiền cước thấp, Thời gian sử dụng ngắn, hoặc mã hóa số nhỏ).

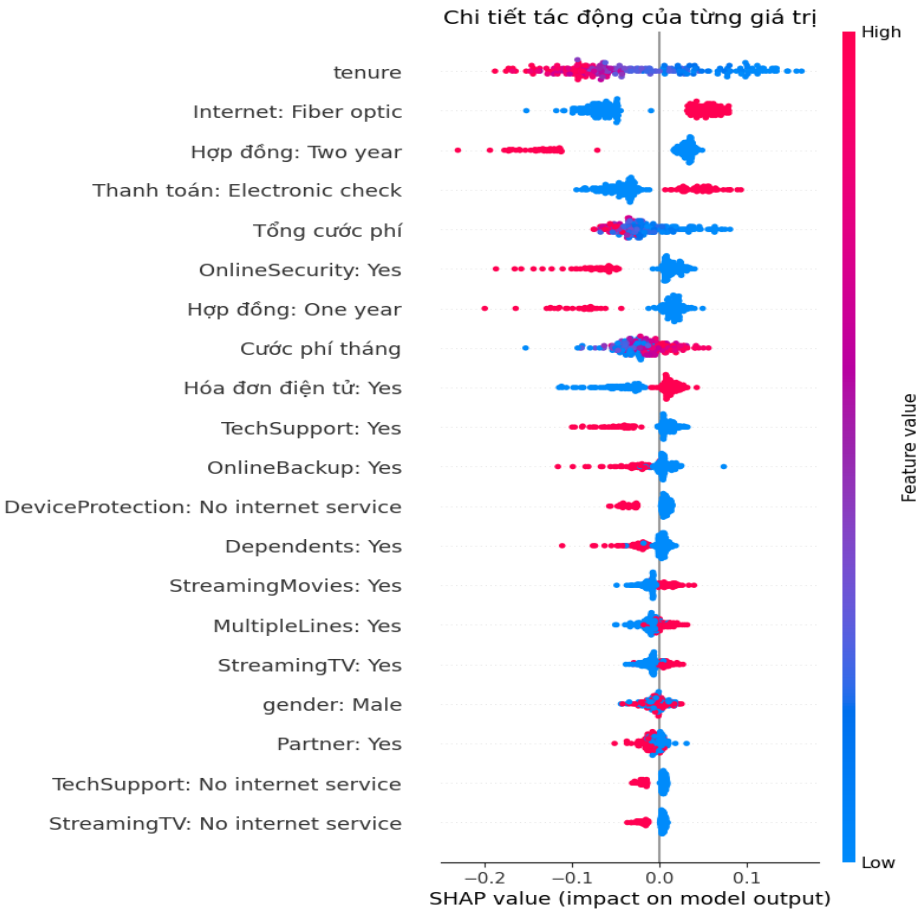

Hình 13. Biểu đồ chi tiết tác động của từng giá trị

Hiểu được ý nghĩa của các chỉ số màu sắc và vị trí trên biểu đồ SHAP, chúng ta sẽ tiến hành phân tích chi tiết các đặc trưng quan trọng nhất (Top Features), bắt đầu với yếu tố có tác động lớn nhất là Tenure:

- Tenure (Thời gian gắn bó):

+ Có một "đuôi" dài các điểm màu xanh (thời gian sử dụng thấp/khách hàng mới) kéo dài về phía bên phải. Các điểm màu đỏ (khách hàng lâu năm) tập trung bên trái.

+ Dữ liệu cho thấy xu hướng rõ rệt: Khách hàng mới (thời gian sử dụng ngắn) là nhóm dễ rời bỏ nhất. Khách hàng càng gắn bó lâu, khả năng rời bỏ càng thấp.

- Internet: Fiber optic (Internet cáp quang):

+ Các điểm màu đỏ (giá trị cao - tương ứng với việc khách hàng Có sử dụng cáp quang) tập trung dày đặc và tách biệt hẳn về phía bên phải. Ngược lại, các điểm màu xanh (giá trị thấp -

tương ứng với việc Không sử dụng cáp quang, ví dụ như dùng DSL (Digital Subscriber Line - Internet cáp đồng truyền thống) hoặc không có internet) tập trung chủ yếu ở phía bên trái.

+ Điều này khẳng định việc sử dụng dịch vụ Internet cáp quang là một yếu tố rủi ro lớn dẫn đến việc rời bỏ. Khách hàng dùng Fiber optic có xác suất hủy dịch vụ cao hơn nhiều so với nhóm còn lại.

- Hợp đồng: Two year:

+ Các điểm màu đỏ (Khách hàng Có cam kết 2 năm) nằm hoàn toàn về phía bên trái. Ngược lại, đám mây điểm màu xanh dày đặc (Không phải hợp đồng 2 năm, thường là hợp đồng tháng hoặc 1 năm) lại dồn về phía bên phải.

+ Điều này khẳng định sự ràng buộc về mặt thời gian là "mỏ neo" quan trọng nhất để giữ chân khách hàng. Những khách hàng thiếu sự cam kết dài hạn (không ký hợp đồng 2 năm) luôn tiềm ẩn rủi ro rời bỏ cao hơn gấp nhiều lần so với nhóm khách hàng trung thành có ràng buộc pháp lý chặt chẽ.

- Thanh toán: Electronic check:

+ Các điểm màu đỏ (Có sử dụng Séc điện tử) tập trung mạnh về phía bên phải, trong khi các điểm màu xanh (Các phương thức khác) nằm về bên trái.

+ Đây là phương thức thanh toán duy nhất có mối liên hệ mật thiết với tỷ lệ rời bỏ cao. Nhóm khách hàng sử dụng Séc điện tử thường kém ổn định hơn so với nhóm thanh toán tự động (thẻ tín dụng, chuyển khoản).

- Tổng cước phí:

+ Một hiện tượng thú vị xuất hiện ở chỉ số này: Các điểm màu đỏ (Tổng cước cao) tập trung về phía bên trái (giảm rủi ro), trong khi các điểm màu xanh (Tổng cước thấp) lại dồn về phía bên phải (tăng rủi ro).

+ Điều này phản ánh tính chất tích lũy của lòng trung thành. Tổng cước phí cao thực chất là "chứng chỉ" của những khách hàng lâu năm (tương quan chặt chẽ với Tenure). Ngược lại, nhóm khách hàng có tổng cước thấp thường là những người mới gia nhập hệ thống - đây chính là nhóm đối tượng thiếu sự gắn kết và dễ dao động nhất.

- OnlineSecurity & TechSupport (Dịch vụ hỗ trợ):

+ Các điểm màu xanh (không sử dụng dịch vụ) nằm hẳn về phía bên phải. Các điểm màu đỏ (có sử dụng) nằm bên trái.

+ Điều này phản ánh tầm quan trọng của hệ sinh thái dịch vụ: Việc thiếu vắng các dịch vụ hỗ trợ như OnlineSecurity hoặc TechSupport làm tăng đáng kể nguy cơ khách hàng rời bỏ. Những khách hàng đăng ký thêm các dịch vụ này thường trung thành hơn.

Tổng hợp các phân tích trên, mô hình đã khắc họa rõ nét chân dung nhóm khách hàng có nguy cơ rời bỏ cao nhất là: Những người mới sử dụng dịch vụ (Tenure thấp) nên tổng cước phí tích lũy còn thấp. Họ đang sử dụng gói Internet cáp quang nhưng lại thiếu sự ràng buộc (không cam kết dài hạn), thường chọn phương thức thanh toán Electronic check và bỏ qua hoàn toàn các dịch vụ hỗ trợ kỹ thuật đi kèm.

5.2.3. Phân tích chi tiết khách hàng cụ thể (Local Explanation)

Để minh họa chi tiết cơ chế ra quyết định của mô hình, nhóm nghiên cứu đã thực hiện lấy mẫu ngẫu nhiên (random sampling) một hồ sơ từ danh sách các khách hàng được dự báo có nguy cơ rời bỏ cao (trên 70%), từ đó chọn được khách hàng Index 156 để làm đối tượng phân tích điển hình. Dưới đây là biểu đồ SHAP Waterfall Plot giải thích các yếu tố tác động đến khách hàng này:

```
================================================================================
 BIỂU ĐỒ 3: TẠI SAO KHÁCH HÀNG (INDEX 156) LẠI RỜI BỎ?
================================================================================
  Xác suất dự báo: 78.00%
```

Hình 14. Khách hàng INDEX 156

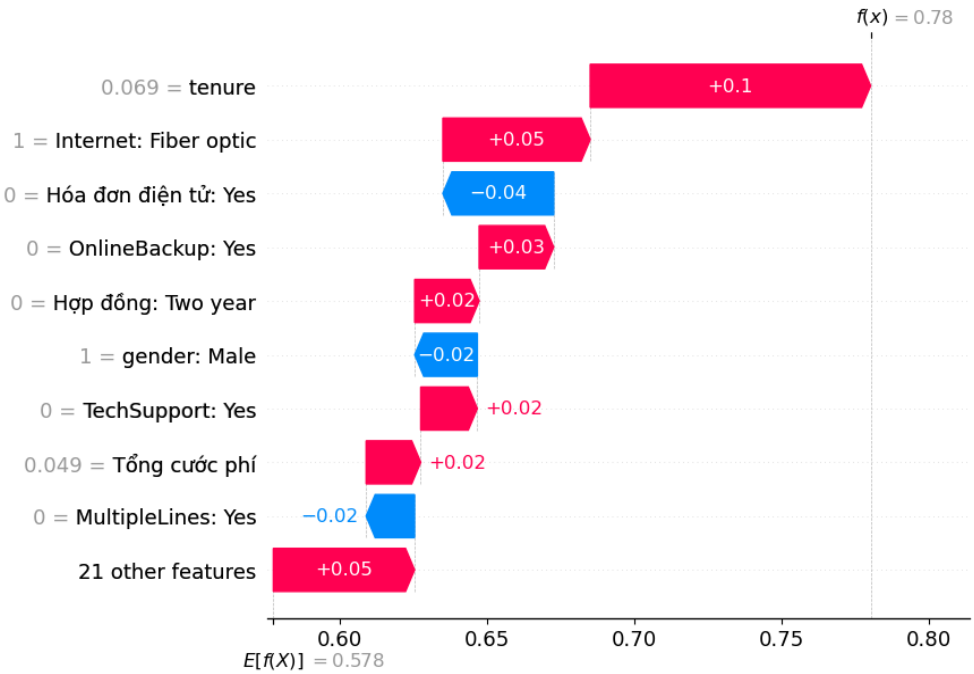

Hình 15. Biểu đồ SHAP Waterfall Plot

Thông tin khách hàng:

- Kết quả dự báo (f(x)): 0,78 (Tương ứng xác suất rời bỏ đạt 78% - Mức rủi ro cao).

- Giá trị cơ sở (E[f(X)]): 0,578 (Mức rủi ro trung bình của toàn bộ tập dữ liệu).

Hồ sơ khách hàng này đang rung lên hồi chuông báo động đỏ với xác suất rời bỏ dịch vụ lên tới 78% (f(x) = 0,78). Đây là một sự gia tăng đáng kể so với mức rủi ro trung bình 0,578 của toàn bộ tập dữ liệu, cho ta thấy khách hàng đang ở trạng thái cực kỳ thiếu ổn định và khả năng huỷ dịch vụ là rất lớn.

Động lực chính đẩy rủi ro leo thang mạnh mẽ nằm ở sự kết hợp giữa việc khách hàng mới và loại hình dịch vụ. Cụ thể do 3 nguyên nhân chính :

(1) Thời gian sử dụng ngắn và Loại hình Internet: Đây là nhóm tác động mạnh nhất. Chỉ số tenure (thời gian sử dụng) ở mức thấp (0,069) đóng góp lớn nhất vào nguy cơ rời bỏ (+0,1 điểm). Thêm vào đó, việc khách hàng sử dụng dịch vụ Internet cáp quang (Internet: Fiber optic) cũng làm tăng rủi ro thêm +0,05 điểm. Điều này thường thấy ở nhóm khách hàng mới lắp mạng cáp quang nhưng chưa hài lòng hoặc đang cân nhắc thay đổi.

(2) Thiếu hụt các dịch vụ bảo vệ và cam kết dài hạn: Khách hàng này không sử dụng các dịch vụ gia tăng quan trọng như Sao lưu trực tuyến (OnlineBackup: Yes = 0, làm tăng +0,03) và Hỗ trợ kỹ thuật (TechSupport: Yes = 0, làm tăng +0,02). Đồng thời, việc không ký hợp đồng dài hạn 2 năm (Hợp đồng: Two year = 0) cũng đóng góp thêm +0,02 điểm vào rủi ro, cho thấy sự gắn kết lỏng lẻo.

(3) Cước phí: Tổng cước phí = 0,049 cũng góp phần nhỏ làm tăng rủi ro (+0,02 điểm).

Yếu tố giảm nhẹ: Ở chiều ngược lại, việc khách hàng không đăng ký hóa đơn điện tử (Hóa đơn điện tử: Yes = 0) đóng vai trò là một yếu tố tích cực nhẹ (thanh màu xanh, -0,04 điểm), ngoài ra còn các yếu tố nhân khẩu học như giới tính Nam (gender: Male) và việc không sử dụng nhiều đường truyền (MultipleLines: Yes = 0) cũng giúp giảm nhẹ rủi ro, mỗi yếu tố đóng góp -0,02 điểm. Tuy nhiên, lực kéo này là quá nhỏ bé so với lực đẩy của các yếu tố rủi ro phía trên để đảo ngược xu hướng rời bỏ của khách hàng.

Kết luận về khách hàng:

Khách hàng này thuộc nhóm "Người dùng cáp quang mới đầy rủi ro". Họ là khách hàng mới (tenure thấp ~0,069), sử dụng dịch vụ Internet tốc độ cao (Fiber optic) nhưng lại thiếu hoàn toàn các dịch vụ bổ trợ giúp tăng độ gắn bó (như Backup hay TechSupport).Việc không có cam kết hợp đồng dài hạn càng làm cho họ dễ dàng rời bỏ dịch vụ. Dù việc thanh toán thủ công (không dùng hóa đơn điện tử) là một tín hiệu tích cực nhỏ, nhưng tổng thể thì họ vẫn đang ở trạng thái rất dễ chuyển sang nhà mạng khác.

6. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

6.1. Kết luận

Qua quá trình nghiên cứu, đồ án đã hoàn thành mục tiêu xây dựng và đánh giá hệ thống dự báo khách hàng rời bỏ trên tập dữ liệu Telco. Thông qua thực nghiệm, nhóm nhận thấy mô hình Random Forest mang lại hiệu quả phân loại tổng thể tốt nhất với độ chính xác 77,79%, trong khi Logistic Regression lại cho thấy ưu thế vượt trội trong khả năng bao phủ rủi ro (Recall đạt 79%). Đặc biệt, việc tích hợp kỹ thuật SHAP đã giúp minh bạch hóa mô hình, khẳng định rằng thời gian gắn bó (Tenure), loại hình dịch vụ Internet (cụ thể là Fiber optic) và hợp đồng (Contract) là ba động lực chính chi phối hành vi khách hàng. Những kết quả định lượng này không chỉ có ý nghĩa về mặt kỹ thuật mà còn cung cấp cơ sở khoa học vững chắc để doanh nghiệp chuyển dịch từ thế bị động sang chủ động giữ chân khách hàng, hoạch định chính sách chăm sóc linh hoạt theo phân khúc rủi ro, đảm bảo phân bổ nguồn lực tối ưu nhằm gia tăng sự gắn kết dài hạn và doanh thu bền vững.

6.2. Hạn chế

Mặc dù đã hoàn thành các mục tiêu đề ra, đề tài vẫn tồn tại một số hạn chế cần khắc phục:

- Hạn chế về mô hình:

+ Mô hình có độ chính xác cao nhất là Random Forest lại có chỉ số Recall khá thấp (0,6). Điều này đồng nghĩa với việc mô hình bỏ sót khoảng 40% số khách hàng thực sự rời bỏ, làm giảm hiệu quả của các chiến dịch giữ chân khách hàng.

+ Mô hình Logistic Regression có Recall tốt nhất (0,79) nhưng lại đánh đổi bằng tỷ lệ báo động giả cao, dẫn đến độ chính xác tổng thể thấp nhất trong 3 mô hình (74,24%).

+ Điểm F1-Score cho lớp khách hàng rời bỏ vẫn chưa thực sự cao, dao động từ 0,59 (Random Forest, XGBoost) đến 0,62 (Logistic Regression), cho thấy sự thách thức trong việc cân bằng giữa độ chính xác và độ phủ.

- Hạn chế về dữ liệu:

+ Dữ liệu hiện tại là dạng “snapshot” tại một thời điểm, thiếu các dữ liệu chuỗi thời gian (time-series) để theo dõi sự thay đổi hành vi khách hàng theo từng giai đoạn.

+ Thiếu các dữ liệu phi cấu trúc (như nội dung phản hồi, ghi âm cuộc gọi CSKH) nên chưa thể phân tích sâu về cảm xúc và trải nghiệm thực tế của khách hàng.

6.3. Hướng phát triển

Để nâng cao tính ứng dụng thực tế và hiệu suất dự báo, nhóm đề xuất các hướng phát triển trong tương lai:

- Cải thiện thuật toán:

+ Thử nghiệm các kỹ thuật tinh chỉnh siêu tham số (Hyperparameter Tuning) sâu hơn (như GridSearch, Bayesian Optimization) để cải thiện chỉ số Recall cho Random Forest và XGBoost.

+ Áp dụng các mô hình học sâu (Deep Learning) như Neural Networks phức tạp hơn để nắm bắt các mối quan hệ phi tuyến tính mà các mô hình truyền thống có thể bỏ sót.

- Mở rộng dữ liệu và ứng dụng:

+ Thu thập thêm dữ liệu hành vi thời gian thực và dữ liệu phản hồi khách hàng để làm giàu đặc trưng đầu vào.

+ Tích hợp mô hình tốt nhất vào một ứng dụng Web (Web App) hoặc Dashboard quản trị, cho phép nhân viên kinh doanh nhập thông tin khách hàng và nhận cảnh báo rủi ro rời bỏ ngay lập tức kèm theo lý do giải thích từ SHAP.

TÀI LIỆU THAM KHẢO

1. IBM. (2017). *Telco Customer Churn dataset*. IBM Sample Data Sets.

2. Market Research Future. (2024). Telecom Analytics Market Research Report.

3. Growth-onomics. (2024). Churn Rate Benchmarks by Industry 2025.

4. N-iX. (2024). *Churn Prediction using Machine Learning: Benefits & Steps*.

5. Parmar, D. S., & Saran, H. K. (2025). *Explainable Artificial Intelligence (XAI): A Review on Building Trust in AI Systems*. International Journal of Computer Trends and Technology.

6. Tridens Technology. (2025). *Why telecom customers churn and how to measure it*. Tridens Technology.

7. *Machine Learning cho dữ liệu dạng bảng*. (n.d.). Mục Đích Của EDA - Machine Learning Cho Dữ Liệu Dạng Bảng.

8. Géron, A. (2019). Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems (2nd ed.). O'Reilly Media.

9. Kuhn, M., & Johnson, K. (2013). Applied Predictive Modeling. Springer.

10. Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: Synthetic Minority Over-Sampling Technique. Journal of Artificial Intelligence Research, 16, 321–357.

11. Breiman, L. (2001). Random forests. *Machine Learning*, *45*(1), 5–32.

12. Google. (n.d.). *Classification: Accuracy, precision, recall*. Google Developers Machine Learning Crash Course.

13. Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*, *30*.

14. Ribeiro, M. T., Singh, S., & Guestrin, C. (2016). "Why should I trust you?": Explaining the predictions of any classifier. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 1135–1144.

15. Saito, T., & Rehmsmeier, M. (2015). The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. *PLoS ONE*, *10*(3), e0118432.

16. Scikit-learn. (n.d.). *Ensemble methods*. Scikit-learn documentation.

17. Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. In Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (pp. 785–794). ACM.

18. Hastie, T., Tibshirani, R., & Friedman, J. (2009). The elements of statistical learning: Data mining, inference, and prediction (2nd ed.). Springer.